



POZNAN UNIVERSITY OF TECHNOLOGY

Wojciech Mioduszewski

Klasyfikacja danych opisanych za pomocą szeregów czasowych

Master's Thesis

Supervisor: dr inż. Jerzy Błaszczyński

Poznań, 2015

Spis treści

1	Wstęp	3
2	Kontekst teoretyczny	5
2.1	Definicja szeregu czasowego	5
2.2	Przykładowe metody analizy danych czasowych[8]	5
2.2.1	Regresja liniowa	5
2.2.2	Wygładzanie (“Smoothing”)	6
2.2.3	Modele ARIMA	6
2.2.4	Analiza spektralna (widmowa)	7
2.3	SAX (Symbolic Aggregate approXimation)	8
2.3.1	Założenia.	8
2.3.2	Schemat działania	8
2.4	DTW (Dynamic Time Warping)	10
2.5	Badane zbiory danych	13
2.5.1	Pacjenci	13
2.5.2	Dane prof. Eamonna Keogh’a[3]	14
3	Koncepcja projektu	15
3.1	Metody przetwarzania danych dla klasyfikatorów	15
3.1.1	Dzielenie sygnału na części.	15
3.1.2	Podejście SAX	15
3.1.3	Zliczanie (eksperyment „Counted”)	15
3.1.4	Dominacja (eksperyment „Dominant”)	17
3.2	Użyte klasyfikatory	19
3.2.1	J48	19
3.2.2	IBk	19
3.2.3	VCDomLem	19
3.2.4	NgramClassifier	19
3.3	Miary[4]	19
3.3.1	Dokładność (ang. accuracy)	20
3.3.2	Wrażliwość (ang. sensitivity)	20
3.3.3	Specyficzność (ang. specificity)	20
3.3.4	Średnia geometryczna (ang. geometric mean)	20

3.3.5	Miara F (ang. F-measure, F1)	21
3.3.6	Procent poprawnie sklasyfikowanych (ang. Percent Correctly Classified)	21
3.4	Posumowanie	21
4	Implementacja	23
4.1	Koncepcja budowy biblioteki	23
4.1.1	Użyte biblioteki pomocnicze	23
4.1.2	Punkt wyjścia	24
4.1.3	Importowanie danych	26
4.1.4	Eksportowanie pliku arff.	26
5	Wnioski	29
A	Podręcznik użytkownika	31
A.1	Uruchomienie projektu w środowisku Eclipse	31
A.2	Uruchomienie programu z linii komend	31
	Bibliografia	33

Wstęp

Cel i zakres pracy

Cel: Opracowanie i implementacja różnych podejść do klasyfikacji danych czasowych.

Zadania:

- Zapoznać się z literaturą tematu.
- Opracować wybrane podejścia do klasyfikacji danych czasowych.
- Zaimplementować i udokumentować zaproponowane rozwiązania.
- Przeprowadzić eksperyment obliczeniowy

Początkowo celem niniejszej pracy była analiza szeregów czasowych zawierających dane ciśnienia w oku pacjentów zdrowych, oraz tych ze zdiagnozowaną jaskrą. Ponadto zamiarem było użycie do tego celu metody SAX, a następnie zbudowanie klasyfikatora potrafiącego sklasyfikować dane wytworzone przez tą metodę. Równie ważne było to, aby nie testować sposobów klasyfikacji tylko i wyłącznie na danych zebranych w celu oceny jaskry, lecz również sprawdzić jak wybrane i stworzone metody poradzą sobie w odniesieniu do innych szeregów czasowych. Kolejną rzeczą, od której należało się uniezależnić są klasyfikatory, dlatego też eksperymenty przeprowadzone zostały na kilku różnych technikach kategoryzowania instancji.

The goal and the scope of the thesis

Celem pracy jest opracowanie / wykonanie analizy / zaprojektowanie /
Struktura pracy jest następująca. W rozdziale 2 przedstawiono przegląd literatury na temat Rozdział 3 jest poświęcony (kilka zdań). Rozdział 4 zawiera (kilka zdań) itd. Rozdział x stanowi podsumowanie pracy.

Kontekst teoretyczny

2.1 Definicja szeregu czasowego

Szereg czasowy jest to seria pewnych obserwacji osadzonych w czasie. Można powiedzieć, że jest to przyporządkowanie danych liczbowych do odpowiadających im punktów w czasie, najczęściej z jednakowymi odstępami między kolejnymi wartościami.

<http://www.cs.put.poznan.pl/jstefanowski/aed/TPtimeseries.pdf>

2.2 Przykładowe metody analizy danych czasowych[8]

Tak obszerny problem jak analiza danych czasowych musi nieść za sobą rozmaite metody przeprowadzania tej analizy. Pomimo tego, że do ostatecznego eksperymentu wybrano tylko jedną z nich - regresję, to postanowiono przedstawić po krótku czym charakteryzują się poszczególne metody oraz ewentualnie dlaczego zostały porzucone.

2.2.1 Regresja liniowa

Regresja w odniesieniu do danych czasowych sprowadza się do estymowania liniowego trendu jaki prezentuje badany szereg. Konceptyjnie metoda polega na stworzeniu funkcji liniowej, która w najbardziej dokładny sposób przybliży wartości na kolejnych obserwacjach. Matematyczny model regresji ma zatem następującą postać:

$$y = ax + b$$

Jako miarę błędu przyjmuje się sumę kwadratów różnicy między oszacowaniami, a wartościami właściwymi.


$$S = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

<http://www.cs.put.poznan.pl/jstefanowski/aed/TPDregresjawieloraka.pdf>

2.2.2 Wygładzanie (“Smoothing”)

Wygładzanie to metoda starająca się zniwelować ponadprzeciętne różnice wartości między kolejnymi pomiarami. Dzięki temu podejściu można dokładniej przyjrzeć się ogólnemu zarysowi funkcji, czy jej okresowymi trendami, kosztem precyzji. Podejście to pozwala zminimalizować ewentualne szумы z badanego zbioru. Metoda ta jako argument przyjmuje szerokość okna k , w ramach którego będą uśredniane wartości. W pierwszym kroku liczy się średnią z k pierwszych wartości szeregu, następnie przesuwając okno o jeden element i znów liczy średnią z k wartości. Wyjściowy zbiór dla n -elementowego zbioru będzie miał $n - k$ wartości.

Poniżej dla porównania zaprezentowano wykres miary TFADJ w przeciągu doby 2.1, oraz jego wygładzony odpowiednik 2.2. Jak widać operacja wygładzania zredukowała skrajne wychylenia szeregu i wyklarowała paraboliczną tendencję tego zbioru.



Rysunek 2.1: Czysty sygnał TFADJ


2.2.3 Modele ARIMA

Model ARIMA (ang. Autoregressive Integrated Moving Average) koncepcyjnie składają się z trzech części - jest to autoregresja, integracja oraz średnia ruchoma.

Autoregresja jest to idea, która skupia się na wyrażeniu bieżącej wartości na podstawie poprzednich. Dla przykładu, funkcja dla $n = 2$ wygląda w ten sposób:

$$x_t = \omega_{t-2}x_{t-2} - \omega_{t-1}x_{t-1} + \omega_t$$

Średnia ruchoma ideowo jest bardzo zbliżona do autoregresji, jednak skupia się na zaburzeniach (ang. lags) w szeregu, a nie bezpośrednio na wartościach. Wzór przedstawia



Rysunek 2.2: Wygładzony sygnał TFADJ

się analogicznie jak w autoregresji.

Integracja z kolei pozwala na zastosowanie modelu ARIMA do procesów niestacjonarnych, które da się sprowadzić do procesów stacjonarnych dzięki przekształceniu oryginalnego sygnału na różnice (ang. difference equations) pomiędzy wartością obecną, a poprzednią.

Podsumowując, modele ARIMA doskonale spisują się w prognozowaniu wartości, bazując na danych historycznych szeregu, jednak nie są najlepszym wyborem jako metoda klasyfikacji. Ponadto metoda nie jest najłatwiejsza matematycznie. Biorąc pod uwagę te argumenty, metoda ta została odrzucona.

2.2.4 Analiza spektralna (widmowa)

Celem analizy spektralnej (ang. spectral analysis) szeregów czasowych jest zidentyfikowanie najczęściej powtarzających się wzorców w czasie, a następnie przybliżenie danego szeregu do procesu okresowego określonego wzorem:

$$x_t = U_1 \cos(2\pi\omega t) + U_2 \sin(2\pi\omega t)$$

gdzie amplituda funkcji to $A = \sqrt{U_1^2 + U_2^2}$.

Jak widać jest to kolejna metoda, za którą stoi solidne matematyczne zaplecze i która wymierzona jest w szeregi cykliczne, z którymi w zbiorze danych pacjentów jaskry nie mamy do czynienia, zatem metodę tę odrzucono.

2.3 SAX (Symbolic Aggregate approXimation)

Już na początkowym etapie rozważań nad zakresem niniejszej pracy zdecydowano, że jednym głównych nurtów jaki przyjmie, będzie przekształcanie sygnału według metody SAX. Mówiąc po krótku, jest to metoda odzwierciedlająca oryginalny sygnał w ciąg znaków, co stwarza możliwości klastfikacji danych za pomocą istniejących już algorytmów tekstowych.

2.3.1 Założenia

Korzystając z pomysłu prof. Eamonna przyjęto założenie, że dla szeregów czasowych o równych odstępach czasowych między pomiarami, można pominąć dane dotyczące momentu, w którym pomiaru dokonano i uprościć ten szereg do sekwencji samych wartości. W następujących rozdziałach przyjęto że operuje się na zbiorze N -elementowym o postaci x_1, x_2, \dots, x_n

2.3.2 Schemat działania

Stworzenie reprezentacji SAX dla szeregu czasowego składa się z trzech etapów:

2.3.2.1 Z-normalizacja szeregu czasowego

Na potrzeby przedstawienia wzoru dla odchylenia standardowego przyjęto następującą definicję sumy elementów zbioru:

$$s_j = \sum_{k=1}^N x_k^j$$

dzięki któremu można przedstawić wzór na odchylenie standardowe tak jak poniżej[2]:

$$std = \sqrt{\frac{Ns_2 - s_1^2}{N(N-1)}}$$

Mając obliczone odchylenie standardowe i średnią wartość dla zbioru, którą wyrażono poniżej symbolem *mean* można przejść do właściwej normalizacji, co oznacza przekształcenie każdego z elementów zbioru w sposób przedstawiony poniżej:

$$x_i = \frac{x_i - mean}{std}$$

2.3.2.2 Dyskretyzacja sygnału za pomocą algorytmu PAA (Piecwise Aggregate Approximation)

Jednym z argumentów, jaki przyjmuje algorytm SAX jest długość łańcucha wyjściowego - co w praktyce sprowadza się do tego na ile części podzielić długość szeregu czasowego. Oznacza to, że metoda zmniejsza wymiarowość szeregu z N do żądanych M elementów. Przebieg algorytmu jest intuicyjny - sekwencja x_1, x_2, \dots, x_N transformowana jest do postaci $y_1 y_2, \dots, y_M$ poprzez podział sekwencji N -elementowej na M równych części według


wzoru[6]:

$$y_i = \frac{M}{N} \sum_{j=\frac{N}{M}(i-1)+1}^{(N/M)i} x_j$$

Poniżej przedstawiono przykładową dyskretyzację dla następującego szeregu czasowego:

i	1	2	3	4	5	6	7	8	9	10
oryginalny sygnał x_i	2	6	3	9	10	9	2	1	7	4

dzieląc szereg dziesięcioelementowy na pięć równych części algorytmem PAA[1]: Dzięki



Rysunek 2.3: Porównanie oryginalnego szeregu czasowego i jego 5-elementowej dyskretyzacji

temu otrzymano redukcję pięciowymiarową:

i	1	2	3	4	5
zdyskretyzowany sygnał y_i	4	6	9.5	1.5	5.5

2.3.2.3 Algorytm SAX

Jak wspomniano wyżej, jednym z argumentów jakie przyjmuje algorytm SAX jest długość sekwencji wyjściowej, zaś drugim - liczba dostępnych liter w alfabecie. Ta liczba precyzuje na ile części podzielić zbiór wartości danego (przetworzonego już) szeregu, a tym samym jakie indeksy (znaki) przypisać wartościom lądującym w poszczególnych zakresach. Do przypisania znaków dla odpowiednich przedziałów potrzebny jest przedział danych zatem obliczyć różnicę między elementem minimalnym a maksymalnym zbioru y


$$d = |\max(y) - \min(y)|$$

a następnie ustalić krok k , ustalający rozmiar okna, dzieląc zbiór wartości d przez liczbę części M . W ostatnim kroku, począwszy od wartości minimalnej przydzielamy kolejne przedziały kolejnym znakom. Dla powyższego przykładu przyjęto alfabet trójelementowy

$\alpha = a, b, c$. Dla $d = 9.5 - 1.5 = 8$ wielkość okna wynosi $k = \frac{8}{3} = 2\frac{2}{3}$. Co prowadzi do podziału:

a	b	c
$< 1\frac{1}{2}, 4\frac{1}{6} >$	$< 4\frac{1}{6}, 6\frac{5}{6} >$	$< 6\frac{5}{6}, 9\frac{1}{2} >$

dzięki czemu otrzymujemy przypisania naniesione na wykres: co oznacza, że ostatecz-



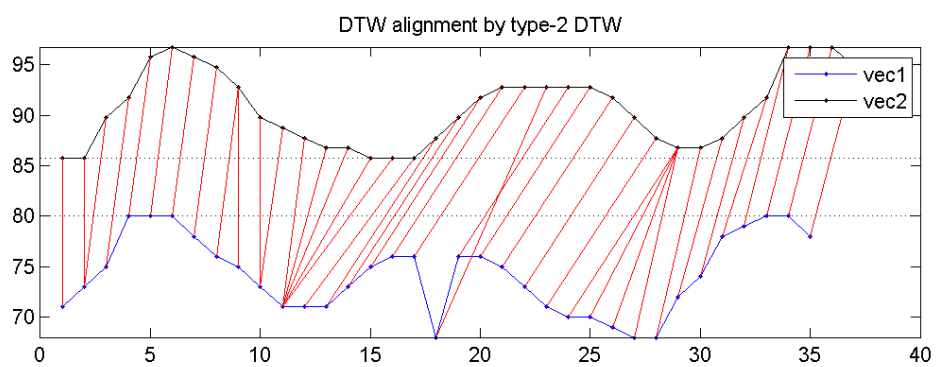

Rysunek 2.4: Oryginalny sygnał z dyskretyzacją i naniesionym SAXem

nym wynikiem metody SAX dla szeregu czasowego x przy zadanych parametrach długości łańcucha wyjściowego 5 oraz alfabetu trójelementowego jest ciąg znaków $ab cab$.

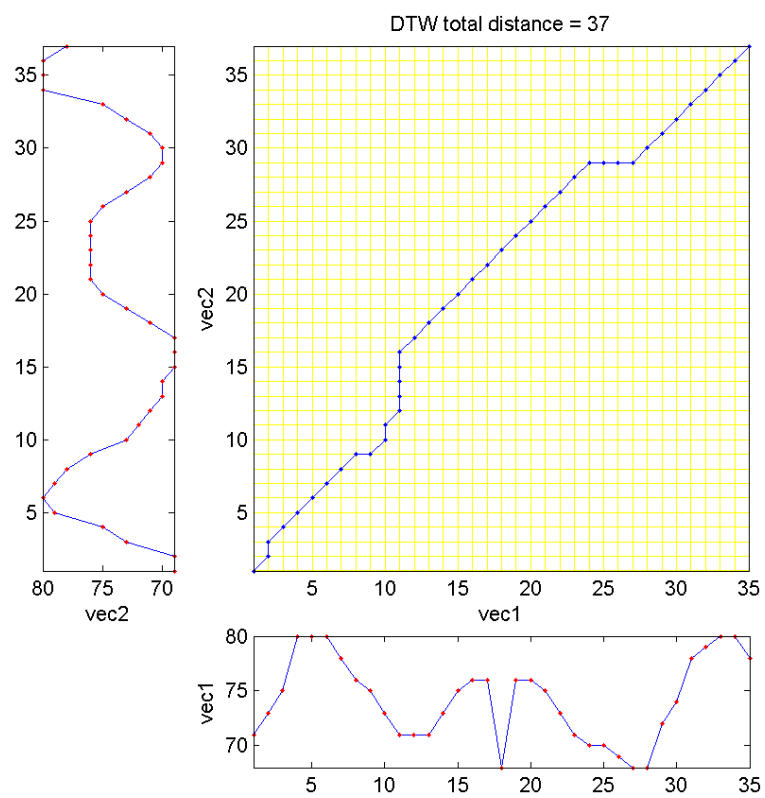
2.4 DTW (Dynamic Time Warping)

Algorytm DTW jest metodą, która stara się wyeliminować błąd porównywania dwóch szeregów czasowych, których charakterystyczne cechy były wobec siebie nieco przesunięte w czasie bądź w jednym szeregu zdarzenie postępowało wolniej niż w drugim - choć nadal było to to samo zdarzenie. Potrafi też poradzić sobie z pojedynczymi błędami pomiaru czy drobnymi szumami. Te cechy widać na rysunku 2.5 na którym sygnał **vec1** wyraźnie dostosowuje się do sygnału **vec2** mimo dużego spadku wartości w połowie przebiegu.

To jak realizowany jest algorytm DTW obrazuje rysunek 2.6. W momencie przyrównywania dwóch sygnałów, tworzona jest macierz odległości, której wartości obliczane są rekurencyjnie. Ostatni wiersz macierzy to różnice między kolejnymi wartościami szeregów. Kolejne wiersze powstają na ich podstawie. Gdy macierz jest już skonstruowana, wybiera się najkrótszą kosztowo ścieżkę między skrajnymi wierzchołkami macierzy - suma wartości komórek, przez które przechodzi ścieżka jest dystansem między tymi szeregami. Należy nadmienić, że metoda ta jest dokładna, lecz za jej skutecznością idzie spory nakład czasowy - czas przetwarzania jest nieporównywalnie większy od pozostałych metod. Szczegółowo zostanie to omówione w rozdziale poświęconym wynikom.



Rysunek 2.5: Dopasowywanie DTW[5]



Rysunek 2.6: Macierz DTW[5]

Teoretycznie metoda jako parametr przyjmuje szerokość okna DTW - określa to ramy części macierzy, na której można szukać ścieżki pomiędzy wierzchołkami. Jednak ze względu na wspomniany już ogromny narzut czasowy, metoda została odpalona tylko na jednej konfiguracji o najmniejszym możliwym - dwuelementowym - oknie DTW.

2.5 Badane zbiory danych

Jak wspomniano wcześniej, podstawowy zbiór, który miał zostać zbadany to pacjenci z jaskrą (lub bez). Z tego powodu będzie on opisany nieco szerzej niż pozostałe zbiory

2.5.1 Pacjenci

Zbiór dostarczony przez dr. J. Błaszczyńskiego. Zbiór zawiera pomiary dla 116 pacjentów, z których 65 to pacjenci zdrowi, a 51 to pacjenci ze zdiagnozowaną jaskrą. Dla każdego pacjenta zebrano 288 pomiarów (pomiar co 5 minut przez całą dobę) tzw. TFADJ <tu rozwinięcie?> będącym przekształceniem zmierzonego w danym momencie ciśnienia w oku. Poniżej poglądowe zdjęcie metody zbierania pomiarów:



Rysunek 2.7: Metoda zbierania pomiarów od pacjentów

2.5.2 Dane prof. Eamonna Keogh'a[3]

Zbiory pobrane od prof. Eamonn'a nie zawierają opisu poszczególnych zbiorów, dlatego też ich tu nie przedstawiono. Jednak przetwarzając dane można było wyciągnąć z nich pewne interesujące statystyki, które przedstawiono w poniższej tabeli (w ostatnim wierszu porównawczo zestawiono zbiór dr. Błaszczyńskiego):

Tablica 2.1: Szczegóły danych

nazwa zbioru	liczba instancji	liczba klas	podział na klasy	długość szeregu
ECG200	200	2	'1' - 67 rekordów '1' - 133 rekordów	96
ECGFiveDays	884	2	'1' - 442 rekordów '2' - 442 rekordów	136
TwoLeadECG	1162	2	'2' - 581 rekordów '1' - 581 rekordów	82
Yoga	3300	2	'1' - 1530 rekordów '2' - 1770 rekordów	426
MoteStrain	1272	2	'2' - 587 rekordów '1' - 685 rekordów	84
ItalyPowerDemand	1096	2	'1' - 547 rekordów '2' - 549 rekordów	24
ChlorineConcentration	4307	3	'1' - 1000 rekordów '3' - 2307 rekordów '2' - 1000 rekordów	166
Two Patterns	5000	3	'2' - 1248 rekordów '3' - 1245 rekordów '4' - 1201 rekordów '1' - 1306 rekordów	128
Wafer	7174	2	'1' - 6402 rekordów '1' - 762 rekordów	152
InlineSkate	650	7	'2' - 100 rekordów '3' - 103 rekordów '7' - 62 rekordów '6' - 98 rekordów '4' - 108 rekordów '5' - 117 rekordów '1' - 62 rekordów	1882
<i>Pacjenci</i>	<i>116</i>	<i>2</i>	<i>'0' - 65 rekordów</i> <i>'1' - 51 rekordów</i>	<i>288</i>

Koncepcja projektu

3.1 Metody przetwarzania danych dla klasyfikatorów

W celu osiągnięcia jak najlepszych wyników, postanowiono przy rozpoczęciu prac nad tą pracą dyplomową spróbować podejścia polegającego na zmodyfikowaniu sygnału wejściowego przed przekazaniem go do klasyfikatora. Zrealizowano to na kilka sposobów, które zostały opisane w niniejszym podrozdziale.

3.1.1 Dzielenie sygnału na części

Pierwszym oraz jeden z prostszych koncepcyjnie pomysłów jaki został wdrożony było podzielenie wejściowego sygnału na części. Przykładowo dla regresji znacznie dzięki temu wzrasta liczba atrybutów, a co za tym idzie - dokładność klasyfikacji. Tak jak klasyczna regresja zwróci dwa argumenty - parametr **a** oraz **b**, tak po podzieleniu sygnału na 3 części dostaniemy aż trzy pary takich parametrów. Jako możliwe wartości tego parametru na przestrzeni eksperymentów wybrano 1, 3 oraz 5. Dodatkowo dla eksperymentu z regresją dodano dodatkowe 10, 20 oraz 48.

3.1.2 Podejście SAX

Opisana wyżej metoda dyskretyzacji sygnału została użyta do kilku spośród przeprowadzonych eksperymentów. Żeby zbadać różne możliwości przebiegu tej dyskretyzacji zdecydowano się na parametryzację tej metody. W ramach dopuszczalnych długości alfabetu wybrano 3, 5 oraz 11 znaków, a w kwestii długości łańcucha wynikowego zdecydowano się na stałą długość 96 znaków.

3.1.3 Zliczanie (eksperyment „Counted”)

Metoda zliczania ściśle bazuje na metodzie SAX - modyfikacje danych następują na poziomie wynikowego łańcucha znaków, a nie czystego szeregu czasowego. Pierwszym krokiem zatem jest wyliczenie łańcucha SAX dla instancji. Następnie łańcuch ten dzieli się na zadaną liczbę części. W kolejnym kroku potrzebny jest kolejny parametr - ngram - który może przyjąć wartość 2 lub 3. Polega on na zliczeniu wszystkich możliwych 2- lub 3gra-

mów w łańcuchu badanej części. Wynikiem są wystąpienia danych ngramów w każdej z części. Poniżej przedstawiono to na przykładzie.

Dla tego przykładu przyjęto podane założenia: metoda otrzymuje 3 rekordy, a dla ich sygnałów metoda SAX wyliczyła odpowiednie łańcuchy:

- r1: 'abaabbbbaabb' z przypisaniem do klasy '1'
- r2: 'abbabaaaabba' z przypisaniem do klasy '1'
- r3: 'aaababbbbaaaa' z przypisaniem do klasy '2'

W tabeli zamieszczono przebieg algorytmu dla podziału na 3 części oraz wyszczególniono 2gramy pojawiające się w ramach każdej z części.

	okres 1	okres 2	okres 3
rekord 1	abaa	bbbb	aabb
	ab	bb	aa
	ba		ab
	aa		bb
rekord 2	abba	baaa	abba
	ab	ba	ab
	bb	aa	bb
	ba		ba
rekord 3	aaab	abbb	aaaa
	aa	ab	aa
	ab	bb	

Tablica 3.1: Podział łańcuchów SAX instancji na 2gramy 'Counted'

W kolejnym kroku należy zliczyć ile razy wystąpił każdy z 2gramów. Wyniki przedstawia tabela

	rekord 1	rekord 2	rekord 3
o1ab	1	1	1
o1ba	1	1	0
o1aa	1	0	2
o1bb	0	1	0
o2bb	3	0	2
o2ba	0	1	0
o2aa	0	2	0
o2ab	0	0	1
o3aa	1	0	3
o3ab	1	1	0
o3bb	1	1	0
o3ba	0	1	0

Tablica 3.2: Zliczenie 2gramów dla instancji przedstawionych w 3.1

Na podstawie tabeli 3.2 generowany jest plik wejściowy **arff** dla klasyfikatora, który dla omawianego przykładu wyglądałby tak, jak pokazano w listingu 3.1.

Listing 3.1: Wynikowy plik arff dla eksperymentu 'Counted'

```
@relation 'Sax counted'

@attribute o1ab numeric
@attribute o1ba numeric
@attribute o1aa numeric
@attribute o1bb numeric
@attribute o2bb numeric
@attribute o2ba numeric
@attribute o2aa numeric
@attribute o2ab numeric
@attribute o3aa numeric
@attribute o3ab numeric
@attribute o3bb numeric
@attribute o3ba numeric

@attribute destClass {1,2}

@data
1,1,1,0,3,0,0,0,1,1,1,0,1
1,1,0,1,0,1,2,0,0,1,1,1,1
1,0,2,0,2,0,0,1,3,0,0,0,2
```

3.1.4 Dominacja (eksperyment „Dominant”)

Eksperyment nazwany eksperymentem dominacyjnym jest łądząco podobny do eksperymentu 'Counted' - różni się jedynie sposobem zliczania ngramów, dlatego zostanie zobrazowany na tym samym przykładzie. Tym razem analizując każdy z ngramów w poszczególnej części zlicza się ngramy będące co najmniej tak samo „wysokie” na każdym z argumentów (tutaj: znaków w łańcuchu) w opcji 'atMost' lub też co najwyżej tak samo opisany na każdym z argumentów ('atLeast') jak ten badany. W tabeli 3.3 przedstawiono jak wyglądają wyniki zliczania z dominacją dla rekordów przedstawionych w tabeli 3.1.

	rekord 1	rekord 2	rekord 3
o1<=ab	2	1	3
o1>=ab	1	2	1
o1<=bb	3	3	3
o1>=bb	0	1	0
o1<=ba	2	1	2
o1>=ba	1	2	0
o1<=aa	1	0	2
o1>=aa	3	3	3

Tablica 3.3: Dominacja ngramów dla rekordów z tabeli 3.1

Jak można zauważyć, w takim podejściu podwaja się liczba argumentów dla każdego rekordu (w tabeli przedstawiono tylko część dotyczącą pierwszego okresu - stąd prefiksy 'o1'). Wartość '2' dla rekordu 1 w wierszu `o1<=ab` oznacza, że spośród ngramów w tym okresie dwa z nich były co najwyżej takie jak 2gram 'ab' - są to 2gramy 'ab' oraz 'aa' - oba występowały jednokrotnie. Z kolei na przykład wartość 0 dla rekordu 3 w wierszu `o1>=ba` oznajmia, że nie było żadnego 2gramu większego lub równego 2gramowi 'ba' w łańcuchu odzwierciedlającym przebieg sygnału dla rekordu nr 3.

Jak zauważono, dla ngramów prezentujących co najmniej najmniejsze lub co najwyżej największe wartości na każdym ze znaków łańcucha, wartości zliczeń są zawsze maksymalne (w tym przykładzie wiersze `'o1<=bb'` oraz `'o1>=aa'`). Nie wnoszą zatem one żadnej informacji godnej uwagi klasyfikatora, zatem wiersze te były wycinane przed eksportem do pliku arff.

Ze względów technicznych w plikach arff znaki '`<=`', '`>=`' zostały zmienione na '`atL`', '`atM`' czyli odpowiednio `atLeast` (co najmniej) oraz `at Most` (co najwyżej). W listingu 3.2 przedstawiono pełny plik arff dla omawianego przypadku w wariantcie eksperymentu 'Dominant'.

Listing 3.2: Wynikowy plik arff dla eksperymentu 'Dominant'

```
@relation 'Sax dominant'

@attribute o1atMaa numeric
@attribute o1atMab numeric
@attribute o1atLab numeric
@attribute o1atMba numeric
@attribute o1atLba numeric
@attribute o1atLbb numeric
@attribute o2atLbb numeric
@attribute o2atMaa numeric
@attribute o2atMba numeric
@attribute o2atLba numeric
@attribute o2atMab numeric
@attribute o2atLab numeric
@attribute o3atMaa numeric
@attribute o3atLbb numeric
@attribute o3atMab numeric
@attribute o3atLab numeric
@attribute o3atMba numeric
@attribute o3atLba numeric
@attribute destClass {1,2}

@data
1,2,1,2,1,0,3,0,0,3,0,3,1,1,2,2,1,1,1
0,1,2,1,2,1,0,2,3,1,2,0,0,1,1,2,1,2,1
2,3,1,2,0,0,2,0,0,2,1,3,3,0,3,0,3,0,2
```

3.2 Użyte klasyfikatory

3.2.1 J48

J48 to jeden z podstawowych klasyfikatorów pakietu **weka**, opierający algorytm klasyfikacji na drzewach decyzyjnych. Jego działanie rozpoczyna się na przypisaniu wszystkich instancji treningowych do jednego liścia. Jeżeli wszystkie elementy należą do tej samej klasy, to algorytm się kończy - jeśli nie, wybiera atrybut, który najlepiej rozdziela instancje w liściu na różne klasy i tworzy odpowiedni liść. Algorytm trwa aż w liściach pozostaną jednorodne grupy elementów lub nie będzie można dobrać kolejnych atrybutów jako kryterium podziału.

3.2.2 IBk

Klasyfikator stworzony do przeprowadzania klasyfikacji za pomocą algorytmu k-najbliższych sąsiadów (ang. KNN: K-Nearest-Neighbors) z pakietu **weka**. Dzięki temu, że klasyfikator ten można w łatwy sposób zmodyfikować na poziomie kodu, dostosowano go również do eksperymentu DTW, który również bazuje na metodzie KNN, jednak używa innego algorytmu wyszukiwania ów najbliższych sąsiadów.

3.2.3 VCDomLem

3.2.4 NgramClassifier

Autorski klasyfikator zbudowany na wzór klasyfikatora pakietu **weka** (rozszerza klasę **weka.classifiers.Classifier**). Jako wejście przyjmuje jeden argument - łańcuch wyjściowy z algorytmu SAX. Następnie dla każdej klasy decyzyjnej wyznacza licznosci występowania danych n-gramów (gdzie n jest parametrem metody). W momencie klasyfikacji instancji zlicza się występowanie ngramów w ramach badanej instancji, by potem zmierzyć dystanse dzielące instancję oraz wszystkie klasy decyzyjne. Instancja zostaje przypisana do klasy, z którą dzieli ją najmniejszy dystans. Aby przedstawić sposób liczenia tej odległości zdefiniowano następującą funkcję: $occ(klasa, ngram)$ która jako wynik zwraca ile wystąpień danego ngramu miało miejsce w ramach podanej klasy decyzyjnej. Analogicznie $occ(instancja, ngram)$ podaje liczbę wystąpień ngramu dla zadanej instancji.

Zatem dla każdej klasy liczony jest następująca odległość między instancją a klasą:

$$dist(instance, class) = \sqrt{\sum_{ngram}^{instance} (occ(klasa, ngram) - occ(instancja, ngram))^2}$$

3.3 Miary[4]

Do oceniania poprawności eksperymentów wybrano sześć miar statystycznych. Niektóre z nich bazują na kilku definicjach c *confussion matrix*, których znaczenie przedstawiono w tabeli poniżej:

	Rzeczywista wartość pozytywna	Rzeczywista wartość negatywna
Przewidywana wartość pozytywna	True Positive	False Positive
Przewidywana wartość negatywna	False Negative	True Negative

3.3.1 Dokładność (ang. accuracy)

Najbardziej znana i intuicyjna miara ewaluacji klasyfikatora to właśnie dokładność. Określa ją stosunek poprawnie sklasyfikowanych instancji do liczby wszystkich instancji. Dzięki swojej prostej koncepcji może być z powodzeniem używana zarówno w problemach binarnych jak i wieloklasowych.

$$Accuracy = \frac{\text{correctly classified instances}}{\text{total instances}}$$

3.3.2 Wrażliwość (ang. sensitivity)

Miara ta, znana również pod nazwą *True positive rate*, skupia się na zobrazowaniu stosunku instancji poprawnie zidentyfikowanych w klasie umownie uznanej za pozytywną do liczby instancji w tej klasie. Na przykładzie zbioru Pacjentów opisywanego w tej pracy można powiedzieć, że jest to proporcja pacjentów poprawnie sklasyfikowanych jako chorzy na jaskrę do wszystkich, którzy są na tę jaskrę chorzy. Wzór na drażliwość podano poniżej:

$$Sensitivity = \frac{TP}{TP + FN}$$

3.3.3 Specyficzność (ang. specificity)

Specyficzność to w pewnym sensie przeciwieństwo drażliwości - uwydatnia proporcję instancji dobrze sklasyfikowanych w klasie uznanej umownie za negatywną do liczby instancji w tej klasie. Ponownie odwołując się do analizowanych tutaj Pacjentów wynik specyficzności to iloraz pacjentów prawidłowo sklasyfikowanych jako zdrowi i liczby wszystkich zdrowych pacjentów. Poniżej przedstawiono jej wzór ogólny:

$$Specificity = \frac{TN}{TN + FP}$$

3.3.4 Średnia geometryczna (ang. geometric mean)

Miara *G-mean* to geometryczne uśrednienie miar wspomnianych powyżej, czyli drażliwości i specyficzności. Estymuje więc skuteczność klasyfikatora zarówno na klasie pozytywnej jak i negatywnej. Dla formalności poniżej przedstawiono jej wzór:

$$Gmean = \sqrt{\frac{TP}{TP + FN} \times \frac{TN}{TN + FP}} = \sqrt{Sensitivity \times Specificity}$$

3.3.5 Miara F (ang. F-measure, F1)

Na potrzeby zobrazowania miary F posłużono się definicjami precyzji (ang. precision) oraz przywołania (ang. recall). Precyzja wyraża to ile było trafień w klasie pozytywnej w odniesieniu do wszystkich instancji, które klasyfikator uznał za należące do klasy pozytywnej ($Precision = \frac{TP}{TP+FP}$). Przywołanie natomiast to nic innego co wspomniana już wcześniej wrażliwość. Miara F1 zaś jest dwukrotnym ilorazem iloczynu precyzji i przywołania oraz ich sumy:

$$F1 = 2 \frac{precision \times recall}{precision + recall}$$

3.3.6 Procent poprawnie sklasyfikowanych (ang. Percent Correctly Classified)

Jest to prosta miara uwidaczniająca udział prawidłowo sklasyfikowanych instancji w odniesieniu do ogółu. Jej wzór prezentuje się następująco:

$$PCC = \frac{correctly\ classified\ instances}{instances}$$

3.4 Posumowanie

Jak szczegółowo opisano wyżej, przeprowadzono aż 7 zróżnicowanych eksperymentów na 11 zbiorach danych. W poniższej tabeli przedstawiono zebrane informacje dotyczące tego jak przetworzono dane zanim przekazano je do klasyfikatora oraz jaki klasyfikator te dane przeliczał.

Nazwa eksperymentu	dane wejściowe	klasyfikator
Regresja	oryginalny sygnał	J48
Dominacja	zliczone dominujące n-gramy SAX	VCDomLem
Zliczanie	zliczone n-gramy SAX	J48
Ngram	SAX	NgramClassifier
KNN	sygnał zdyskretyzowany metodą SAX	IBk
DTW	oryginalny sygnał	IBk
Bagging	zliczone n-gramy SAX	J48

Tablica 3.4: Zrealizowane eksperymenty

Implementacja

4.1 Koncepcja budowy biblioteki

Wiodącym założeniem przyświecającym pracom implementacyjnym nad biblioteką obliczeniową było podążanie za dobrymi praktykami wytwarzania oprogramowania według Roberta C. Martina - z głównym naciskiem na OCP (Open Closed Principle)[7] - zasadę „otwarte-zamknięte”. Oznacza to, że oprogramowanie ma być otwarte na zmiany, lecz zamknięte na modyfikacje - starano się zatem osiągnąć stan, w którym istniejący kod można rozszerzyć z jak najmniejszym wysiłkiem wniesionym w edycję istniejącego kodu. Szczegóły tej idei przedstawiono w poniższych sekcjach.

4.1.1 Użyte biblioteki pomocnicze

Żeby móc w pełni opisać funkcjonalność i sposób budowy programu należy nadmienić jakimi bibliotekami wspomagano się podczas tego procesu.

4.1.1.1 Weka

Najważniejsza biblioteka, z którą program współpracuje najściślej. Wiedząc, że Weka jest często używana do klasyfikacji czy uczenia maszynowego, autor chciał stworzyć narzędzie kompatybilne z programem stworzonym na Uniwersytecie w australijskim Waikato. Kilka kluczowych klas programu autora rozszerza klasy pakietu **weka** stwarzając możliwości wykorzystania rozmaitych składowych tego systemu. Ponadto używanie klas takich jak **weka.classifiers.Evaluation** do przeprowadzania eksperymentów daje pewność, że wykorzystywane rozwiązanie jest dobrze przetestowane i powinno zwracać rzetelne wyniki. Stąd również przyjęto format wyjściowy plików klasyfikacyjnych ***.arff**

4.1.1.2 jMotif

Z pakietu **jMotif** zaczerpnięto metody zajmujące się tworzeniem łańcucha danych na podstawie zadanego szeregu czasowego za pomocą algorytmu SAX.

4.1.1.3 JFreeChart

Biblioteka służąca do rysowania wykresów. Bardzo pomocna w początkowej fazie implementacji, kiedy autorowi zależało na zobrazowaniu przebiegu szeregów szasowych. Ich wizualizacja mogła przyczynić się do lepszego zrozumienia zależności między przebiegami, a diagnozą pacjenta.

4.1.1.4 Jxl

Dzięki pakietowi `jxl` w początkowej fazie implementacji autor mógł ściśle współpracować z arkuszami kalkulacyjnymi w celu raportowania danych do plików `.xls` w celu ich dalszej analizy statystycznej.

4.1.1.5 joda-time

W momencie gdy prace nad tą pracą dyplomową zostały rozpoczęte, wsparcie dla obiektów typu `data` czy `czas` było dla autora niewystarczające, dlatego zdecydowano się na wykorzystanie biblioteki `joda-time` w celu zapewnienia wymaganej obsługi tego rodzaju danych.

4.1.1.6 fast-dtw

Pakiet `fast-dtw` dostarcza obsługę obliczeniową dla eksperymentu bazującego na algorytmie Dynamic Time Warping, dzięki czemu autor mógł skorzystać z gotowego, przetestowanego i relatywnie wydajnego czasowo i pamięciowo rozwiązania dla tego celu.

4.1.1.7 apache-commons

W momentach gdy brakowało pewnych struktur danych w obecnej wersji Java - takich jak choćby `Pair` (ang. `para`) lub należało skorzystać z popularnych metod takich jak obliczenie regresji, korzystano z bibliotek `apache-commons`.

4.1.2 Punkt wyjścia

Praca programu zorientowana jest wokół obiektu `Workflow` (ang. „przepływ”, „proces”) - ma on na celu zdefiniowanie następujących po sobie kroków składających się na przebieg eksperymentu - począwszy od wczytania danych, aż do wypisania ostatecznego wyniku. Jego rdzeń zawiera się w abstrakcyjnej klasie `WorkflowBase` która posiada trzy główne metody - odpalenia przebiegu pełnego eksperymentu, wygenerowania pliku `arff` dla eksperymentu oraz wyliczenia wyniku eksperymentu dla zadanego pliku `arff`. Ponadto jest w stanie opisać podstawowe statystyki wczytanych danych, takie jak liczba klas decyzyjnych, podział instancji w klasach, czy liczba atrybutów w ramach instancji. Aby stworzyć własny eksperyment wystarczy stworzyć klasę dziedziczącą z `WorkflowBase` oraz zaimplementować wymagane metody. Przykładowy szkic takiej klasy przedstawiono na listingu 4.1: Jeżeli wczytane przez nas dane wymagają jakiegokolwiek ingerencji obliczeniowej - tak jak na przykład eksperyment `Counted`, to fragment kodu odpowiadający za te obliczenia powinien znaleźć się w metodzie `processData`. Jak widać w przywołanym listingu, wszystkie

Listing 4.1: Kod eksperymentu Counted

```
1 public class CountedWorkflow extends WorkflowBase {
2
3     private List<CalculatedRecord> calculatedRecords;
4
5     public CountedWorkflow(DivisionOptions divisionOption, boolean glaucoma) {
6         super(divisionOption, glaucoma);
7     }
8
9     @Override
10    protected Instances buildInstances() {
11        exporter = new CountedSaxArffBuilder(calculatedRecords);
12        return exporter.buildInstances();
13    }
14
15    @Override
16    protected void processData() throws Exception {
17        calculatedRecords = new ArrayList<CalculatedRecord>();
18
19        for (IRecord record : records) {
20            ArrayList<HashMap<String, Integer>> periodicallyCountedNgrams =
21                new ArrayList<HashMap<String, Integer>>();
22
23            List<String> dividedSax = DataDivider.divideStringRegularly(
24                record.getSaxString(), divisionPartsAmount);
25
26            for (String elem : dividedSax) {
27                HashMap<String, Integer> ngramCountMap = PeriodicNgramCounter
28                    .slashStringAndCountNgrams(elem, windowLen);
29                periodicallyCountedNgrams.add(ngramCountMap);
30            }
31
32            CalculatedRecord calcRecord = new CalculatedRecord(
33                periodicallyCountedNgrams, record.getDestinationClass());
34            calculatedRecords.add(calcRecord);
35        }
36    }
37
38    @Override
39    protected void setConcerningParams() {
40        concerningParameters.add(Pair.of("parts", divisionPartsAmount));
41        concerningParameters.add(Pair.of("ngram", windowLen));
42        concerningParameters.add(Pair.of("alpha", Config.getInstance().getSaxAlphabeatSize()));
43    }
44 }
```

wymagane kalkulacje odbywają się w tym fragmencie kodu. Kolejna metoda to `buildInstances` która odpowiada za ustawienie odpowiedniego eksportera danych (w szczególności zostanie omówiony niżej) oraz przekazanie mu przeliczonych danych. Za jego pomocą tworzony jest obiekt `Instances`, który musi zostać zwrócony jako wynik metody. Funkcja `setConcerningParams` służy już tylko do tego, aby podczas wyświetlania wyniku eksperymentu wypisać, które parametry programu mają wpływ na pracę tego eksperymentu, oraz jakie ich wartości zostały ustawione podczas bieżącego wykonania.

4.1.3 Importowanie danych

Importowanie danych zostało rozdzielone ze względu na dwa różne formaty danych jakie potrafi wczytać program. Ostateczną wersją danych pacjentów jest opisanie danych każdego pacjenta w osobnym pliku `.csv`. W każdym z nich podany jest identyfikator pacjenta, oraz dane z poszczególnych pomiarów ciśnienia w oku. W ramach każdego pomiaru udostępnionych jest sporo danych, takich jak godzina o której pomiar został zdjęty, pozycja ciała w której znajdował się pacjent itp. choć na potrzebę tej pracy korzystano tylko z miary `TFADJ`. Jedyną informacją, której nie ma w tym pliku to diagnoza - ta opisana jest w pliku zbiorczym dla wszystkich pacjentów. W kolejnych wierszach znajdują się pary identyfikator pacjenta - diagnoza.

Drugim formatem, jaki wspiera program jest format danych prof. Eamonna. Ich charakterystyka jest prosta - każdy nowy wiersz w pliku to nowa instancja. W ramach każdego wiersza figurują atrybuty oddzielone spacjami, z których pierwszy to atrybut decyzyjny, a kolejne to szereg wartości składające się w szereg czasowy dla tej instancji. Tak jak wspomniano wcześniej, zapis ten pomija dokładny czas zebrania pomiaru. Klasy odpowiadające za wczytywanie danych to odpowiednio `PatientDataImporter2` oraz `DataImporterEamonn`.

4.1.4 Eksportowanie pliku arff

Jedną z funkcji programu jest wygenerowanie pliku `arff` w którym zapisane są już przetworzone dane o instancjach, gotowe do klasyfikacji klasyfikatorami `weki`. Aby stworzyć taki eksporter na własny użytek można posłużyć się klasą abstrakcyjną `ArffExporterBase` i rozszerzyć ją. Eksporter taki zostanie poniżej opisany na przykładzie `RegressionArffBuilder`. Jego kod można znaleźć na listingu 4.2. Klasa nadrzędna wymaga od programisty zaimplementowania dwóch metod oraz konstruktora.

Metoda `setAttributes` służy do tego aby nadać i nazwać atrybuty dla formatu danych jaki zdecydowano użyć w docelowym pliku `arff`. W pliku dla eksperymentu `Regression` tworzy się tyle par `slope-intercept` (współczynników a i b regresji) na ile części został podzielony sygnał. Należy również pamiętać o tym aby w liście atrybutów zawrzeć również atrybut decyzyjny.

W funkcji `buildInstances` programista musi obsłużyć przeniesienie danych ze struktury w jakiej trzymał dane po ewentualnych obliczeniach w metodzie `processData` klasy `WorkflowBase` do obiektu `Instances`. Dzięki temu umożliwiające będzie wygodne eksportowanie pliku `arff` oraz przeprowadzanie eksperymentu za pomocą klasy `Evaluation`. Ostatnią rzeczą o którą trzeba zadbać, to wywołanie metod `setDestinationClasses` oraz `setAttributes` w konstruktorze tak jak pokazano na wspomnianym listingu.

Listing 4.2: Kod eksportera dla eksperymentu Regression

```

1  public class RegressionArffBuilder extends ArffExporterBase {
2
3      private List<RegressionRow> input;
4
5      public RegressionArffBuilder(List<RegressionRow> input) {
6          this.input = input;
7          setDestinationClasses(input);
8          setAttributes();
9      }
10
11     protected void setAttributes() {
12         attrInfo = new FastVector();
13
14         int regressionCount = input.stream().findFirst().get()
15             .getRegressionResults().size();
16
17         for (int i = 0; i < regressionCount; i++) {
18             attrInfo.addElement(new Attribute(String.format("slope%d", i + 1)));
19             attrInfo.addElement(new Attribute(String.format("intercept%d",
20                 i + 1)));
21         }
22
23         Attribute destClassAttribute = null;
24         try {
25             destClassAttribute = constructDestinationClassesNominalAttribute(destClasses);
26         } catch (Exception e) {
27             e.printStackTrace();
28         }
29         attrInfo.addElement(destClassAttribute);
30     }
31
32     @Override
33     public Instances buildInstances() {
34         instances = new Instances("Regression", attrInfo, input.size());
35         instances.setClassIndex(instances.numAttributes() - 1);
36
37         for (RegressionRow row : input) {
38             Instance instance = new Instance(attrInfo.size());
39             int attrIdx = 0;
40             for (RegressionResult regResult : row.getRegressionResults()) {
41                 instance.setValue(attrIdx++, regResult.getSlope());
42                 instance.setValue(attrIdx++, regResult.getIntercept());
43             }
44
45             int destClassIndex = getIndexOfDestinationClass(row
46                 .getDestinationClass());
47             instance.setValue(attrIdx, destClassIndex);
48             instances.add(instance);
49         }

```

```
50         return instances;
51     }
52 }
```

Wnioski

Podręcznik użytkownika

A.1 Uruchomienie projektu w środowisku Eclipse

A.2 Uruchomienie programu z linii komend

Bibliografia

- [1] Opis przeprowadzenia algorytmu paa w bibliotece jmotif. http://jmotif.github.io/sax-vsm_site/morea/algorithm/PAA.html. Ostatni dostęp: 2015-09-26.
- [2] Wzór na odchylenie standardowe. https://en.wikipedia.org/wiki/Standard_deviation#Rapid_calculation_methods. Ostatni dostęp: 2015-09-26.
- [3] Yanping Chen, Eamonn Keogh, Bing Hu, Nurjahan Begum, Anthony Bagnall, Abdullah Mueen, and Gustavo Batista. The ucr time series classification archive, July 2015. www.cs.ucr.edu/~eamonn/time_series_data/, ostatni dostęp 24.09.2015.
- [4] Diane J. Cook and Narayanan C. Krishnan. *Activity Learning: Discovering, Recognizing, and Predicting Human Behavior from Sensor Data (Wiley Series on Parallel and Distributed Computing)*. Wiley, 2015.
- [5] Roger Jang. *Data Clustering and Pattern Recognition*. <http://mirlab.org/jang/books/dcpr/>, ostatni dostęp 24.09.2015.
- [6] Jessica Lin, Eamonn Keogh, Stefano Lonardi, and Bill Chiu. A symbolic representation of time series, with implications for streaming algorithms. pages 2–11, 2003.
- [7] Robert C. Martin. Design principles and design patterns. = <http://citeseerx.ist.psu.edu/viewdoc/summary?doi=10.1.1.94.8854>.
- [8] Robert H. Shumway and David S. Stoffer. *Time Series Analysis and Its Applications: With R Examples (Springer Texts in Statistics)*. Springer, 2010.