



POZNAN UNIVERSITY OF TECHNOLOGY

Wojciech Mioduszewski

Klasyfikacja danych opisanych za pomocą szeregów czasowych

Praca magisterska

Promotor: dr inż. Jerzy Błaszczyński

Poznań, 2015

Spis treści

1	Wstęp	3
2	Kontekst teoretyczny	5
2.1	Definicja szeregu czasowego	5
2.2	Przykładowe metody analizy danych czasowych[16]	5
2.2.1	Regresja liniowa[18]	5
2.2.2	Wygładzanie (ang. smoothing)	5
2.2.3	Modele ARIMA	6
2.2.4	Analiza spektralna (widmowa)	7
2.3	SAX (Symbolic Aggregate approXimation)	7
2.3.1	Założenia.	8
2.3.2	Schemat działania	8
2.4	DTW (Dynamic Time Warping)	10
2.5	Badane zbiory danych	13
2.5.1	Pacjenci	13
2.5.2	Dane prof. Eamonna Keogh’a[7]	13
3	Koncepcja projektu	15
3.1	Metody przetwarzania danych dla klasyfikatorów	15
3.1.1	Dzielenie sygnału na części.	15
3.1.2	Podejście SAX	15
3.1.3	Zliczanie (eksperyment „Counted”)	15
3.1.4	Dominacja (eksperyment „Dominant”)	17
3.1.5	K najbliższych sąsiadów (ang. KNN - k Nearest Neighbors).	19
3.1.6	Bagging	19
3.2	Użyte klasyfikatory	19
3.2.1	J48	19
3.2.2	IBk	19
3.2.3	VC-DomLEM[4]	19
3.2.4	Basic Ngram Classifier	20
3.2.5	Bagging	20

3.3	Miary[8]	20
3.3.1	Dokładność (ang. accuracy)	20
3.3.2	Wrażliwość (ang. sensitivity)	21
3.3.3	Specyficzność (ang. specificity)	21
3.3.4	Średnia geometryczna (ang. geometric mean)	21
3.3.5	Procent poprawnie sklasyfikowanych (ang. Percent Correctly Classified)	22
3.4	Posumowanie	22
4	Implementacja	23
4.1	Koncepcja budowy biblioteki	23
4.1.1	Użyte biblioteki pomocnicze	23
4.1.2	Punkt wyjścia	24
4.1.3	Importowanie danych	26
4.1.4	Eksportowanie pliku arff	26
4.2	Serwisy zewnętrzne	28
4.2.1	Git	28
4.2.2	Travis	28
5	Wnioski	29
5.1	Analiza wyników - część podstawowa	29
5.2	Analiza wyników - część rozszerzona	36
5.3	Podsumowanie	40
A	Podręcznik użytkownika	43
A.1	Uruchomienie projektu w środowisku Eclipse	43
A.2	Uruchomienie programu z linii komend	43
B	Wyniki	45
B.1	Wyniki dla najlepszych zestawów parametrów w ramach eksperymentu	45
B.1.1	Eksperymenty Zliczania, Regresji oraz Ngram	45
B.1.2	Eksperymenty DTW, KNN oraz Bagging	47
B.1.3	Eksperymenty używające klasyfikatora VC-DomLEM	49
	Bibliografia	53

Wstęp

Cel i zakres pracy

Cel: Opracowanie i implementacja różnych podejść do klasyfikacji danych czasowych.

Zadania:

- Zapoznać się z literaturą tematu.
- Opracować wybrane podejścia do klasyfikacji danych czasowych.
- Zaimplementować i udokumentować zaproponowane rozwiązania.
- Przeprowadzić eksperyment obliczeniowy

Początkowo celem niniejszej pracy była analiza szeregów czasowych zawierających dane ciśnienia w oku pacjentów zdrowych, oraz tych ze zdiagnozowaną jaskrą. Ponadto zamiarem było użycie do tego celu metody SAX, a następnie zbudowanie klasyfikatora potrafiącego sklasyfikować dane wytworzone przez tą metodę. Następnie, aby nie testować sposobów klasyfikacji tylko i wyłącznie na danych zebranych w celu oceny jaskry, lecz również sprawdzić jak wybrane i stworzone metody poradzą sobie w odniesieniu do innych szeregów czasowych, rozszerzono zbiór danych o kolejne zestawy szeregów czasowych. Kolejną rzeczą, od której należało się uniezależnić są klasyfikatory, dlatego też eksperymenty przeprowadzone zostały z wykorzystaniem różnych typów klasyfikatorów.

Ostatecznie po wielu testach wyklarowano sześć eksperymentów, których wyniki porównano i zinterpretowano. Składowe każdego z eksperymentów zostały dokładnie opisane.

W rozdziale 2 przedstawiono kilka podejść analizy szeregów czasowych wybranych z przeanalizowanej literatury. Ponadto zademonstrowano działanie dwóch kluczowych algorytmów rozważanych w tej pracy, to jest algorytmu SAX oraz DTW. Rozdział 3 poświęcono zobrazowaniu koncepcji projektu, toteż rozdział ten skupia się na przestudiowaniu różnych sposobów przetwarzania danych jeszcze zanim te trafią do klasyfikatora. Czytelnik znajdzie tu również krótki opis użytych klasyfikatorów, a także miary jakie użyto do oceniania dokładności klasyfikacji.

Rozdział 4 przedstawia sposób implementacji programu potrzebnego do przeprowadzenia eksperymentów. Zamieszczono tutaj zwięzłe opisy użytych bibliotek, oraz szczegółowy opis importu oraz eksportu danych - tak aby w przyszłości nie było problemu z ewentualnym rozszerzeniem istniejącego kodu. Rozdział 5 zawiera analizę wyników oraz wnioski, a tym samym stanowi podsumowanie niniejszej pracy.

Kontekst teoretyczny

2.1 Definicja szeregu czasowego

Szereg czasowy jest to seria pewnych obserwacji osadzonych w czasie. Można powiedzieć, że jest to przyporządkowanie danych liczbowych do odpowiadających im punktów w czasie, najczęściej z jednakowymi odstępami między kolejnymi wartościami[17].

2.2 Przykładowe metody analizy danych czasowych[16]

Tak obszerny problem jak analiza danych czasowych musi nieść za sobą rozmaite metody przeprowadzania tej analizy. Wprawdzie do ostatecznego eksperymentu wybrano tylko dwie z nich - regresję oraz DTW, to postanowiono przedstawić pokrótce czym charakteryzują się poszczególne metody oraz ewentualnie dlaczego zostały porzucone.

2.2.1 Regresja liniowa[18]

Regresja w odniesieniu do danych czasowych sprowadza się do estymowania liniowego trendu jaki prezentuje badany szereg. Konceptyjnie metoda polega na stworzeniu funkcji liniowej, która w najbardziej dokładny sposób przybliży wartości na kolejnych obserwacjach. Matematyczny model regresji ma zatem następującą postać:

$$y = ax + b$$

Jako miarę błędu przyjmuje się sumę kwadratów różnicy między oszacowaniami, a wartościami właściwymi.


$$S = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

2.2.2 Wygładzanie (ang. smoothing)

Wygładzanie to metoda starająca się zniwelować ponadprzeciętne różnice wartości między kolejnymi pomiarami. Dzięki temu podejściu można dokładniej przyjrzeć się ogólnemu

zarysowi funkcji, czy jej okresowymi trendami, kosztem precyzji. Podejście to pozwala zminimalizować ewentualne szумы z badanego zbioru. Metoda ta jako argument przyjmuje szerokość okna k , w ramach którego będą uśredniane wartości. W pierwszym kroku liczy się średnią z k pierwszych wartości szeregu, następnie przesuwa okno o jeden element i znów liczy średnią z k wartości. Wyjściowy zbiór dla n -elementowego zbioru będzie miał $n - k$ wartości.

Poniżej dla porównania zaprezentowano wykres miary TFADJ w przeciągu doby 2.1, oraz jego wygładzony odpowiednik 2.2. Jak widać operacja wygładzania zredukowała skrajne wychylenia szeregu i wyklarowała paraboliczną tendencję tego zbioru.



Rysunek 2.1: Czysty sygnał TFADJ

2.2.3 Modele ARIMA


Model ARIMA (ang. Autoregressive Integrated Moving Average) koncepcyjnie składają się z trzech części - jest to autoregresja, integracja oraz średnia ruchoma.

Autoregresja jest to metoda, która skupia się na wyrażeniu bieżącej wartości na podstawie poprzednich. Dla przykładu, funkcja dla $n = 2$ wygląda w ten sposób:

$$x_t = \omega_{t-2}x_{t-2} - \omega_{t-1}x_{t-1} + \omega_t$$

Średnia ruchoma ideowo jest bardzo zbliżona do autoregresji, jednak skupia się na zaburzeniach (ang. lags) w szeregu, a nie bezpośrednio na wartościach. Wzór przedstawia się analogicznie jak w autoregresji.

Integracja z kolei pozwala na zastosowanie modelu ARIMA do procesów niestacjonarnych, które da się sprowadzić do procesów stacjonarnych dzięki przekształceniu ory-



Rysunek 2.2: Wygładzony sygnał TFADJ

ginalnego sygnału na różnice (ang. difference equations) pomiędzy wartością obecną, a poprzednią.

Podsumowując, modele ARIMA doskonale spisują się w prognozowaniu wartości, bazując na danych historycznych szeregu, jednak nie są najlepszym wyborem jako metoda klasyfikacji. Ponadto metoda nie jest najłatwiejsza matematycznie. Biorąc pod uwagę te argumenty, metoda ta została odrzucona.

2.2.4 Analiza spektralna (widmowa)

Celem analizy spektralnej (ang. spectral analysis) szeregów czasowych jest zidentyfikowanie najczęściej powtarzających się wzorców w czasie, a następnie przybliżenie danego szeregu do procesu okresowego określonego wzorem:

$$x_t = U_1 \cos(2\pi\omega t) + U_2 \sin(2\pi\omega t)$$

gdzie amplituda funkcji to $A = \sqrt{U_1^2 + U_2^2}$.

Jak widać jest to kolejna metoda, za którą stoi solidne matematyczne zaplecze i która wymierzona jest w szeregi cykliczne, z którymi w zbiorze danych pacjentów jaskry nie mamy do czynienia, zatem metodę tę odrzucono.

2.3 SAX (Symbolic Aggregate approXimation)

Już na początkowym etapie rozważań nad zakresem niniejszej pracy zdecydowano, że jednym głównych nurtów jaki przyjmie, będzie przekształcanie sygnału według metody

SAX. Mówiąc pokrótce, jest to metoda odzwierciedlająca oryginalny sygnał w ciąg znaków, co stwarza możliwości klasyfikacji danych za pomocą istniejących już algorytmów tekstowych.

2.3.1 Założenia

Korzystając z pomysłu prof. Eamonna przyjęto założenie, że dla szeregów czasowych o równych odstępach czasowych między pomiarami, można pominąć dane dotyczące momentu, w którym pomiaru dokonano i uprościć ten szereg do sekwencji samych wartości. W następujących rozdziałach przyjęto że operuje się na zbiorze N -elementowym o postaci x_1, x_2, \dots, x_n

2.3.2 Schemat działania

Stworzenie reprezentacji SAX dla szeregu czasowego składa się z trzech etapów:

2.3.2.1 Z-normalizacja szeregu czasowego

Na potrzeby przedstawienia wzoru dla odchylenia standardowego przyjęto następującą definicję sumy elementów zbioru:

$$s_j = \sum_{k=1}^N x_k^j$$

dzięki któremu można przedstawić wzór na odchylenie standardowe tak jak poniżej[2]:

$$std = \sqrt{\frac{Ns_2 - s_1^2}{N(N-1)}}$$

Mając obliczone odchylenie standardowe i średnią wartość dla zbioru, którą wyrażono poniżej symbolem *mean* można przejść do właściwej normalizacji, co oznacza przekształcenie każdego z elementów zbioru w sposób przedstawiony poniżej:

$$x_i = \frac{x_i - mean}{std}$$

2.3.2.2 Dyskretyzacja sygnału za pomocą algorytmu PAA (Piecwise Aggregate Approximation)


Jednym z argumentów, jaki przyjmuje algorytm SAX jest długość łańcucha wyjściowego - co w praktyce sprowadza się do tego na ile części podzielić długość szeregu czasowego. Oznacza to, że metoda zmniejsza wymiarowość szeregu z N do żądanych M elementów. Przebieg algorytmu jest intuicyjny - sekwencja x_1, x_2, \dots, x_N transformowana jest do postaci $y_1 y_2, \dots, y_M$ poprzez podział sekwencji N -elementowej na M równych części według wzoru[13]:

$$y_i = \frac{M}{N} \sum_{j=\frac{N}{M}(i-1)+1}^{(N/M)i}$$

Poniżej przedstawiono przykładową dyskretyzację dla następującego szeregu czasowego:

i	1	2	3	4	5	6	7	8	9	10
oryginalny sygnał x_i	2	6	3	9	10	9	2	1	7	4

dzieląc szereg dziesięcioelementowy na pięć równych części algorytmem PAA[1]: Dzięki



Rysunek 2.3: Porównanie oryginalnego szeregu czasowego i jego 5-elementowej dyskretyzacji

temu otrzymano redukcję pięciowymiarową:

i	1	2	3	4	5
zdyskretyzowany sygnał y_i	4	6	9.5	1.5	5.5

2.3.2.3 Algorytm SAX


Jak wspomniano wyżej, jednym z argumentów jakie przyjmuje algorytm SAX jest długość sekwencji wyjściowej, zaś drugim - liczba dostępnych liter w alfabecie. Ta liczba precyzuje na ile części podzielić zbiór wartości danego (przetworzonego już) szeregu, a tym samym jakie indeksy (znaki) przypisać wartościom lądującym w poszczególnych zakresach. Do przypisania znaków dla odpowiednich przedziałów potrzebny jest przedział danych zatem obliczyć różnicę między elementem minimalnym a maksymalnym zbioru y

$$d = |\max(y) - \min(y)|$$

a następnie ustalić krok k , ustalający rozmiar okna, dzieląc zbiór wartości d przez liczbę części M . W ostatnim kroku, począwszy od wartości minimalnej przydzielamy kolejne przedziały kolejnym znakom. Dla powyższego przykładu przyjęto alfabet trójelementowy $alpha = a, b, c$. Dla $d = 9.5 - 1.5 = 8$ wielkość okna wynosi $k = \frac{8}{3} = 2\frac{2}{3}$. Co prowadzi do podziału:

a	b	c
$< 1\frac{1}{2}, 4\frac{1}{6})$	$< 4\frac{1}{6}, 6\frac{5}{6})$	$< 6\frac{5}{6}, 9\frac{1}{2} >$

dzięki czemu otrzymujemy przypisania naniesione na wykres: co oznacza, że ostatecz-



Rysunek 2.4: Oryginalny sygnał z dyskretyzacją i naniesionym SAXem

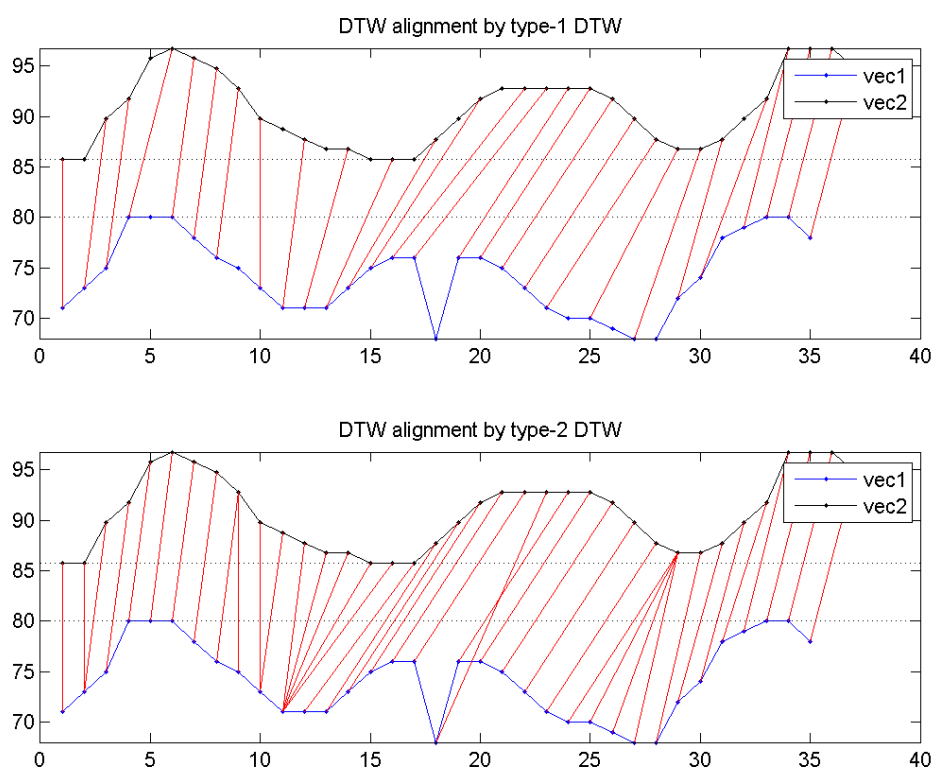
nym wynikiem metody SAX dla szeregu czasowego x przy zadanych parametrach długości łańcucha wyjściowego 5 oraz alfabetu trójelementowego jest ciąg znaków *abcab*.

2.4 DTW (Dynamic Time Warping)

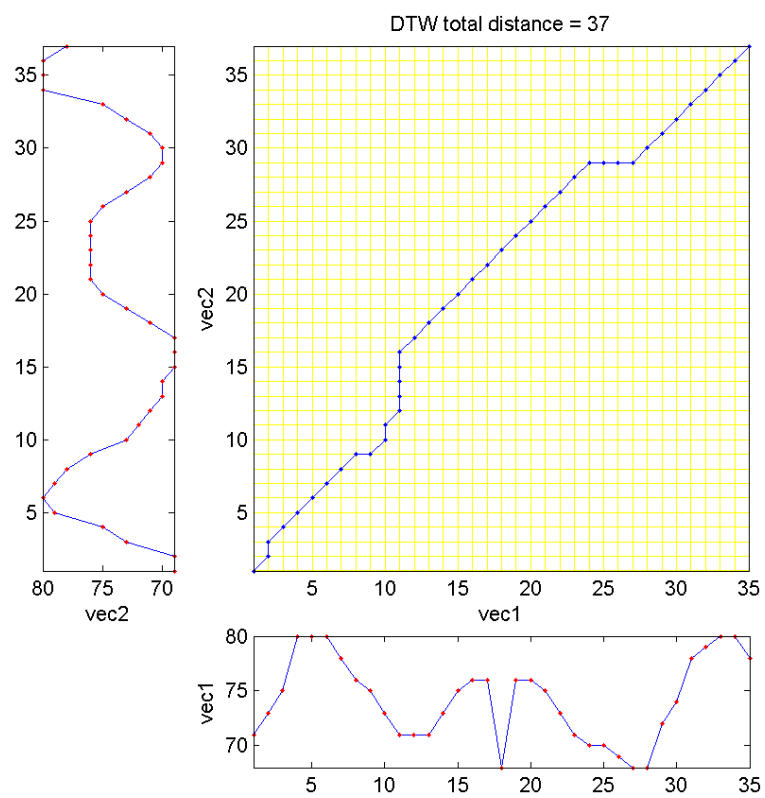
Algorytm DTW jest metodą, która stara się wyeliminować błąd porównywania dwóch szeregów czasowych, których charakterystyczne cechy były wobec siebie nieco przesunięte w czasie bądź w jednym szeregu zdarzenie postępowało wolniej niż w drugim - choć nadal było to to samo zdarzenie. Potrafi też poradzić sobie z pojedynczymi błędami pomiaru czy drobnymi szumami. Te cechy widać na rysunku 2.5 na którym sygnał *vec1* wyraźnie dostosowuje się do sygnału *vec2* mimo dużego spadku wartości w połowie przebiegu.

To jak realizowany jest algorytm DTW obrazuje rysunek 2.6. W momencie przyrównywania dwóch sygnałów, tworzona jest macierz odległości, której wartości obliczane są rekurencyjnie. Ostatni wiersz macierzy to różnice między kolejnymi wartościami szeregów. Kolejne wiersze powstają na ich podstawie. Gdy macierz jest już skonstruowana, wybiera się najkrótszą kosztowo ścieżkę między skrajnymi wierzchołkami macierzy - suma wartości komórek, przez które przechodzi ścieżka jest dystansem między tymi szeregami. Należy nadmienić, że metoda ta jest dokładna, lecz za jej skutecznością idzie spory nakład czasowy - czas przetwarzania jest nieporównywalnie większy od pozostałych metod. Szczegółowo zostanie to omówione w rozdziale poświęconym wynikom.

Teoretycznie metoda jako parametr przyjmuje szerokość okna DTW - określa to ramy części macierzy, na której można szukać ścieżki pomiędzy wierzchołkami. Jednak ze względu na wspomniany już ogromny narzut czasowy, metoda została odpalona tylko na jednej konfiguracji o najmniejszym możliwym - dwuelementowym - oknie DTW.



Rysunek 2.5: Dopasowywanie DTW[12]



Rysunek 2.6: Macierz DTW[12]

2.5 Badane zbiory danych

Jak wspomniano wcześniej, podstawowy zbiór, który miał zostać zbadany to pacjenci z jaskrą (lub bez). Z tego powodu będzie on opisany nieco szerzej niż pozostałe zbiory

2.5.1 Pacjenci

Zbiór dostarczony przez dr. J. Błaszczyńskiego. Zbiór zawiera pomiary dla 116 pacjentów, z których 65 to pacjenci zdrowi, a 51 to pacjenci ze zdiagnozowaną jaskrą. Dla każdego pacjenta zebrano 288 pomiarów (pomiar co 5 minut przez całą dobę) tzw. TFADJ (Trigger Fish Adjusted) będącym przekształceniem zmierzonego w danym momencie ciśnienia w oku. Poniżej poglądowe zdjęcie metody zbierania pomiarów:



Rysunek 2.7: Metoda zbierania pomiarów od pacjentów

2.5.2 Dane prof. Eamonna Keogh'a[7]

Zbiory pobrane od prof. Eamonna nie zawierają opisu poszczególnych zbiorów, dlatego też ich tu nie przedstawiono. Jednak przetwarzając dane można było wyciągnąć z nich pewne interesujące statystyki, które przedstawiono w poniższej tabeli (w ostatnim wierszu porównawczo zestawiono zbiór dr. Błaszczyńskiego):

Tablica 2.1: Szczegóły danych

nazwa zbioru	liczba instancji	liczba klas	podział na klasy	długość szeregu
ECG200	200	2	'1' - 67 rekordów '1' - 133 rekordów	96
ECGFiveDays	884	2	'1' - 442 rekordów '2' - 442 rekordów	136
TwoLeadECG	1162	2	'2' - 581 rekordów '1' - 581 rekordów	82
Yoga	3300	2	'1' - 1530 rekordów '2' - 1770 rekordów	426
MoteStrain	1272	2	'2' - 587 rekordów '1' - 685 rekordów	84
ItalyPowerDemand	1096	2	'1' - 547 rekordów '2' - 549 rekordów	24
ChlorineConcentration	4307	3	'1' - 1000 rekordów '3' - 2307 rekordów '2' - 1000 rekordów	166
Two Patterns	5000	3	'2' - 1248 rekordów '3' - 1245 rekordów '4' - 1201 rekordów '1' - 1306 rekordów	128
Wafer	7174	2	'1' - 6402 rekordów '1' - 762 rekordów	152
InlineSkate	650	7	'2' - 100 rekordów '3' - 103 rekordów '7' - 62 rekordów '6' - 98 rekordów '4' - 108 rekordów '5' - 117 rekordów '1' - 62 rekordów	1882
<i>Pacjenci</i>	<i>116</i>	<i>2</i>	<i>'0' - 65 rekordów</i> <i>'1' - 51 rekordów</i>	<i>288</i>

Koncepcja projektu

3.1 Metody przetwarzania danych dla klasyfikatorów

W celu osiągnięcia jak najlepszych wyników, postanowiono przy rozpoczęciu prac nad tą pracą dyplomową spróbować podejścia polegającego na zmodyfikowaniu sygnału wejściowego przed przekazaniem go do klasyfikatora. Zrealizowano to na kilka sposobów, które zostały opisane w niniejszym podrozdziale.

3.1.1 Dzielenie sygnału na części

Pierwszym oraz jeden z prostszych koncepcyjnie pomysłów jaki został wdrożony było podzielenie wejściowego sygnału na części. Przykładowo dla regresji znacznie dzięki temu wzrasta liczba atrybutów, a co za tym idzie - dokładność klasyfikacji. Tak jak klasyczna regresja zwróci dwa argumenty - parametr **a** oraz **b**, tak po podzieleniu sygnału na 3 części dostaniemy aż trzy pary takich parametrów. Jako możliwe wartości tego parametru na przestrzeni eksperymentów wybrano 1, 3 oraz 5. Dodatkowo dla eksperymentu z regresją dodano dodatkowe 10, 20 oraz 48.

3.1.2 Podejście SAX

Opisana wyżej metoda dyskretyzacji sygnału została użyta do kilku spośród przeprowadzonych eksperymentów. Żeby zbadać różne możliwości przebiegu tej dyskretyzacji zdecydowano się na parametryzację tej metody. W ramach dopuszczalnych długości alfabetu wybrano 3, 5 oraz 11 znaków, a w kwestii długości łańcucha wynikowego zdecydowano się na stałą długość 96 znaków.

3.1.3 Zliczanie (eksperyment „Counted”)

Metoda zliczania ściśle bazuje na metodzie SAX - modyfikacje danych następują na poziomie wynikowego łańcucha znaków, a nie czystego szeregu czasowego. Pierwszym krokiem zatem jest wyliczenie łańcucha SAX dla instancji. Następnie łańcuch ten dzieli się na zadaną liczbę części. W kolejnym kroku potrzebny jest kolejny parametr - ngram - który może przyjąć wartość 2 lub 3. Polega on na zliczeniu wszystkich możliwych 2- lub 3gra-

mów w łańcuchu badanej części. Wynikiem są wystąpienia danych ngramów w każdej z części. Poniżej przedstawiono to na przykładzie.

Dla tego przykładu przyjęto podane założenia: metoda otrzymuje 3 rekordy, a dla ich sygnałów metoda SAX wyliczyła odpowiednie łańcuchy:

- r1: 'abaabbbbaabb' z przypisaniem do klasy '1'
- r2: 'abbabaaaabba' z przypisaniem do klasy '1'
- r3: 'aaababbbbaaaa' z przypisaniem do klasy '2'

W tabeli zamieszczono przebieg algorytmu dla podziału na 3 części oraz wyszczególniono 2gramy pojawiające się w ramach każdej z części.

	okres 1	okres 2	okres 3
rekord 1	abaa	bbbb	aabb
	ab	bb	aa
	ba		ab
	aa		bb
rekord 2	abba	baaa	abba
	ab	ba	ab
	bb	aa	bb
	ba		ba
rekord 3	aaab	abbb	aaaa
	aa	ab	aa
	ab	bb	

Tablica 3.1: Podział łańcuchów SAX instancji na 2gramy 'Counted'

W kolejnym kroku należy zliczyć ile razy wystąpił każdy z 2gramów. Wyniki przedstawia tabela

	rekord 1	rekord 2	rekord 3
o1ab	1	1	1
o1ba	1	1	0
o1aa	1	0	2
o1bb	0	1	0
o2bb	3	0	2
o2ba	0	1	0
o2aa	0	2	0
o2ab	0	0	1
o3aa	1	0	3
o3ab	1	1	0
o3bb	1	1	0
o3ba	0	1	0

Tablica 3.2: Zliczenie 2gramów dla instancji przedstawionych w 3.1

Na podstawie tabeli 3.2 generowany jest plik wejściowy **arff** dla klasyfikatora, który dla omawianego przykładu wyglądałby tak, jak pokazano w listingu 3.1.

Listing 3.1: Wynikowy plik arff dla eksperymentu 'Counted'

```
@relation 'Sax counted'

@attribute o1ab numeric
@attribute o1ba numeric
@attribute o1aa numeric
@attribute o1bb numeric
@attribute o2bb numeric
@attribute o2ba numeric
@attribute o2aa numeric
@attribute o2ab numeric
@attribute o3aa numeric
@attribute o3ab numeric
@attribute o3bb numeric
@attribute o3ba numeric

@attribute destClass {1,2}

@data
1,1,1,0,3,0,0,0,1,1,1,0,1
1,1,0,1,0,1,2,0,0,1,1,1,1
1,0,2,0,2,0,0,1,3,0,0,0,2
```

3.1.4 Dominacja (eksperyment „Dominant”)

Eksperyment nazwany eksperymentem dominacyjnym jest łudząco podobny do eksperymentu 'Counted' - różni się jedynie sposobem zliczania ngramów, dlatego zostanie zobrazowany na tym samym przykładzie. Tym razem analizując każdy z ngramów w poszczególnej części zlicza się ngramy będące co najmniej tak samo „wysokie” na każdym z argumentów (tutaj: znaków w łańcuchu) w opcji 'atMost' lub też co najwyżej tak samo opisany na każdym z argumentów ('atLeast') jak ten badany. W tabeli 3.3 przedstawiono jak wyglądają wyniki zliczania z dominacją dla rekordów przedstawionych w tabeli 3.1.

	rekord 1	rekord 2	rekord 3
o1<=ab	2	1	3
o1>=ab	1	2	1
o1<=bb	3	3	3
o1>=bb	0	1	0
o1<=ba	2	1	2
o1>=ba	1	2	0
o1<=aa	1	0	2
o1>=aa	3	3	3

Tablica 3.3: Dominacja ngramów dla rekordów z tabeli 3.1

Jak można zauważyć, w takim podejściu podwaja się liczba argumentów dla każdego rekordu (w tabeli przedstawiono tylko część dotyczącą pierwszego okresu - stąd prefiksy 'o1'). Wartość '2' dla rekordu 1 w wierszu `o1<=ab` oznacza, że spośród ngramów w tym okresie dwa z nich były co najwyżej takie jak 2gram 'ab' - są to 2gramy 'ab' oraz 'aa' - oba występowały jednokrotnie. Z kolei na przykład wartość 0 dla rekordu 3 w wierszu `o1>=ba` oznajmia, że nie było żadnego 2gramu większego lub równego 2gramowi 'ba' w łańcuchu odzwierciedlającym przebieg sygnału dla rekordu nr 3.

Jak zauważono, dla ngramów prezentujących co najmniej najmniejsze lub co najwyżej największe wartości na każdym ze znaków łańcucha, wartości zliczeń są zawsze maksymalne (w tym przykładzie wiersze `'o1<=bb'` oraz `'o1>=aa'`). Nie wnoszą zatem one żadnej informacji godnej uwagi klasyfikatora, zatem wiersze te były wycinane przed eksportem do pliku arff.

Ze względów technicznych w plikach arff znaki '`<=`', '`>=`' zostały zmienione na '`atL`', '`atM`' czyli odpowiednio `atLeast` (co najmniej) oraz `at Most` (co najwyżej). W listingu 3.2 przedstawiono pełny plik arff dla omawianego przypadku w wariantcie eksperymentu 'Dominant'.

Listing 3.2: Wynikowy plik arff dla eksperymentu 'Dominant'

```
@relation 'Sax dominant'

@attribute o1atMaa numeric
@attribute o1atMab numeric
@attribute o1atLab numeric
@attribute o1atMba numeric
@attribute o1atLba numeric
@attribute o1atLbb numeric
@attribute o2atLbb numeric
@attribute o2atMaa numeric
@attribute o2atMba numeric
@attribute o2atLba numeric
@attribute o2atMab numeric
@attribute o2atLab numeric
@attribute o3atMaa numeric
@attribute o3atLbb numeric
@attribute o3atMab numeric
@attribute o3atLab numeric
@attribute o3atMba numeric
@attribute o3atLba numeric
@attribute destClass {1,2}

@data
1,2,1,2,1,0,3,0,0,3,0,3,1,1,2,2,1,1,1
0,1,2,1,2,1,0,2,3,1,2,0,0,1,1,2,1,2,1
2,3,1,2,0,0,2,0,0,2,1,3,3,0,3,0,3,0,2
```

3.1.5 K najbliższych sąsiadów (ang. KNN - k Nearest Neighbors)

W eksperymencie zorientowanym wokół algorytmu KNN zdecydowano się na dość nowatorskie podejście z dyskretyzacją danych. Przeważnie używając algorytmu najbliższych sąsiadów, za dane wejściowe uznaje się czysty zebrany sygnał. W tym projekcie postanowiono zdyskretyzować dane używając do tego metody SAX, a dopiero potem przekazać jej rezultat do klasyfikatora KNN, dzięki czemu zysaliśmy swego rodzaju normalizację danych.

3.1.6 Bagging

Przygotowanie danych dla eksperymentu Bagging przebiegało dokładnie w ten sam sposób co dla eksperymentu Zliczającego. Eksperymenty różniły się sposobem użycia klasyfikatora. Oba eksperymenty skorzystały z J48, lecz dla Baggingu był on opakowany w meta-klasyfikator `weka.classifiers.meta.Bagging`, który bliżej zostanie opisany w podrozdziale (3.2.5).

3.2 Użyte klasyfikatory

3.2.1 J48

J48 to jeden z podstawowych klasyfikatorów pakietu `weka`, opierający algorytm klasyfikacji na drzewach decyzyjnych. Jego działanie rozpoczyna się na przypisaniu wszystkich instancji treningowych do jednego liścia. Jeżeli wszystkie elementy należą do tej samej klasy, to algorytm się kończy - jeśli nie, wybiera atrybut, który najlepiej rozdziela instancje w liściu na różne klasy i tworzy odpowiedni liść. Algorytm trwa aż w liściach pozostaną jednorodne grupy elementów lub nie będzie można dobrać kolejnych atrybutów jako kryterium podziału.

3.2.2 IBk

Klasyfikator stworzony do przeprowadzania klasyfikacji za pomocą algorytmu k-najbliższych sąsiadów (ang. KNN: K-Nearest-Neighbors) z pakietu `weka`. Dzięki temu, że klasyfikator ten można w łatwy sposób zmodyfikować na poziomie kodu, dostosowano go również do eksperymentu DTW, który również bazuje na metodzie KNN, jednak używa innego algorytmu wyszukiwania ów najbliższych sąsiadów.

3.2.3 VC-DomLEM[4]

Algorytm VC-DomLEM bazuje na schemacie sekwencyjnego pokrywania [15][9]. Algorytm ten pokrywa obszary pozytywne, utworzone przez VC-DRSA [3], za pomocą reguł decyzyjnych o wymaganej spójności. VC-DomLEM jest inspirowany algorytmem LEM2 [11], a także adaptacją tego algorytmu dla danych porządkowych DomLEM [10].

3.2.4 Basic Ngram Classifier

Autorski klasyfikator zbudowany na wzór klasyfikatora pakietu weka (rozszerza klasę `weka.classifiers.Classifier`). Jako wejście przyjmuje jeden argument - łańcuch wyjściowy z algorytmu SAX. Następnie dla każdej klasy decyzyjnej wyznacza licznosci występowania danych n-gramów (gdzie n jest parametrem metody). W momencie klasyfikacji instancji zlicza się występowanie ngramów w ramach badanej instancji, by potem zmierzyć dystanse dzielące instancję oraz wszystkie klasy decyzyjne. Instancja zostaje przypisana do klasy, z którą dzieli ją najmniejszy dystans. Aby przedstawić sposób liczenia tej odległości zdefiniowano następującą funkcję: $occ(klasa, ngram)$ która jako wynik zwraca ile wystąpień danego ngramu miało miejsce w ramach podanej klasy decyzyjnej. Analogicznie $occ(instancja, ngram)$ podaje liczbę wystąpień ngramu dla zadanej instancji.

Zatem dla każdej klasy liczony jest następująca odległość między instancją a klasą:

$$dist(instance, class) = \sqrt{\sum_{ngram}^{instance} (occ(klasa, ngram) - occ(instancja, ngram))^2}$$

3.2.5 Bagging

Bagging[5] to metoda polegająca na generowaniu wielu wersji klasyfikatora po to by uzyskać kształt klasyfikatora zagregowanego. Wówczas o przyporządkowaniu instancji do klasy decyduje głosowanie poszczególnych klasyfikatorów. Kolejne wersje klasyfikatora powstają na podstawie wylosowanej (losowanie ze zwracaniem) próby instancji na której wybrany klasyfikator przeprowadza uczenie.

3.3 Miary[8]

Do oceniania poprawności eksperymentów wybrano sześć miar statystycznych. Niektóre z nich bazują na kilku definicjach c *confussion matrix*, których znaczenie przedstawiono w tabeli poniżej:

	Rzeczywista wartość pozytywna	Rzeczywista wartość negatywna
Przewidywana wartość pozytywna	True Positive	False Positive
Przewidywana wartość negatywna	False Negative	True Negative

3.3.1 Dokładność (ang. accuracy)

Najbardziej znana i intuicyjna miara ewaluacji klasyfikatora to właśnie dokładność. Określa ją stosunek poprawnie sklasyfikowanych instancji do liczby wszystkich instancji. Dzięki swojej prostej koncepcji może być z powodzeniem używana zarówno w problemach binarnych jak i wieloklasowych.

$$Accuracy = \frac{correctly\ classified\ instances}{total\ instances}$$

3.3.2 Wrażliwość (ang. sensitivity)

Miara ta, znana również pod nazwą *True positive rate*, skupia się na zobrazowaniu stosunku instancji poprawnie zidentyfikowanych w klasie umownie uznanej za pozytywną do liczby instancji w tej klasie. Na przykładzie zbioru Pacjentów opisywanego w tej pracy można powiedzieć, że jest to proporcja pacjentów poprawnie sklasyfikowanych jako chorzy na jaskrę do wszystkich, którzy są na tę jaskrę chorzy. Wzór na wrażliwość podano poniżej:

$$Sensitivity = \frac{TP}{TP + FN}$$

3.3.3 Specyficzność (ang. specificity)

Specyficzność to w pewnym sensie przeciwieństwo wrażliwości - uwydatnia proporcję instancji dobrze sklasyfikowanych w klasie uznanej umownie za negatywną do liczby instancji w tej klasie. Ponownie odwołując się do analizowanych tutaj Pacjentów wynik specyficzności to iloraz pacjentów prawidłowo sklasyfikowanych jako zdrowi i liczby wszystkich zdrowych pacjentów. Poniżej przedstawiono jej wzór ogólny:

$$Specificity = \frac{TN}{TN + FP}$$

3.3.4 Średnia geometryczna (ang. geometric mean)

Miara *G-mean* to geometryczne uśrednienie miar wspomnianych powyżej, czyli wrażliwości i specyficzności. Estymuje więc skuteczność klasyfikatora zarówno na klasie pozytywnej jak i negatywnej. Dla formalności poniżej przedstawiono jej wzór:

$$Gmean = \sqrt{\frac{TP}{TP + FN} \times \frac{TN}{TN + FP}} = \sqrt{Sensitivity \times Specificity}$$

Jak można zauważyć dalej w wynikach, dla zbiorów wieloklasowych miary Sensitivity, Specificity oraz GMean nie były obliczane, ze względu na to, że musiałyby zostać przedstawione dla każdej klasy osobno. Porównywanie takich wyników między zbiorem trójklasowym a siedmioklasowym byłoby niemiarodajne, dlatego też w zbiorach posiadających co najmniej 3 klasy zrezygnowano z obliczania tych trzech miar.

3.3.4.1 Miara F (ang. F-measure, F1)

Na potrzeby zobrazowania miary F posłużono się definicjami precyzji (ang. precision) oraz przywołania (ang. recall). Precyzja wyraża to ile było trafień w klasie pozytywnej w odniesieniu do wszystkich instancji, które klasyfikator uznał za należące do klasy pozytywnej ($Precision = \frac{TP}{TP + FP}$). Przywołanie natomiast to nic innego co wspomniana już wcześniej wrażliwość. Miara F1 zaś jest dwukrotnym ilorazem iloczynu precyzji i przywołania oraz ich sumy:

$$F1 = 2 \frac{precision \times recall}{precision + recall}$$

3.3.5 Procent poprawnie sklasyfikowanych (ang. Percent Correctly Classified)

Jest to prosta miara uwidaczniająca udział prawidłowo sklasyfikowanych instancji w odniesieniu do ogółu. Jej wzór prezentuje się następująco:

$$PCC = \frac{\text{correctly classified instances}}{\text{instances}}$$

3.4 Posumowanie

Jak szczegółowo opisano wyżej, przeprowadzono aż 7 zróżnicowanych eksperymentów na 11 zbiorach danych. W tabeli 3.4 przedstawiono zebrane informacje dotyczące tego jak przetworzono dane zanim przekazano je do klasyfikatora oraz jaki klasyfikator te dane przeliczał. Dla przejrzystości użyto skrótu 'sax' dla pary parametrów: rozmiar ngramu oraz liczba liter w alfabecie.

Nazwa eksperymentu	dane wejściowe	klasyfikator	parametry
Regresja	oryginalny sygnał	J48	części
Dominacja	zliczone dominujące n-gramy SAX	VC-DomLEM	części, sax
Zliczanie	zliczone n-gramy SAX	J48	części, sax
Ngram	SAX	NgramClassifier	sax
KNN	sygnał zdyskretyzowany metodą SAX	IBk	sax, k
DTW	oryginalny sygnał	IBk	k, okno dtw
Bagging	zliczone n-gramy SAX	J48	części, sax

Tablica 3.4: Zrealizowane eksperymenty

Implementacja

4.1 Koncepcja budowy biblioteki

Wiodącym założeniem przyświecającym pracom implementacyjnym nad biblioteką obliczeniową było podążanie za dobrymi praktykami wytwarzania oprogramowania według Roberta C. Martina - z głównym naciskiem na OCP (Open Closed Principle)[14] - zasadę „otwarte-zamknięte”. Oznacza to, że oprogramowanie ma być otwarte na zmiany, lecz zamknięte na modyfikacje - starano się zatem osiągnąć stan, w którym istniejący kod można rozszerzyć z jak najmniejszym wysiłkiem wniesionym w edycję istniejącego kodu. Szczegóły tej idei przedstawiono w poniższych sekcjach.

4.1.1 Użyte biblioteki pomocnicze

Żeby móc w pełni opisać funkcjonalność i sposób budowy programu należy nadmienić jakimi bibliotekami wspomagano się podczas tego procesu.

4.1.1.1 Weka

Najważniejsza biblioteka, z którą program współpracuje najściślej. Wiedząc, że Weka jest często używana do klasyfikacji czy uczenia maszynowego, autor chciał stworzyć narzędzie kompatybilne z programem stworzonym na Uniwersytecie w australijskim Waikato. Kilka kluczowych klas programu autora rozszerza klasy pakietu `weka` stwarzając możliwości wykorzystania rozmaitych składowych tego systemu. Ponadto używanie klas takich jak `weka.classifiers.Evaluation` do przeprowadzania eksperymentów daje pewność, że wykorzystywane rozwiązanie jest dobrze przetestowane i powinno zwracać rzetelne wyniki. Stąd również przyjęto format wyjściowy plików klasyfikacyjnych `*.arff`

4.1.1.2 jMotif

Z pakietu `jMotif` zaczerpnięto metody zajmujące się tworzeniem łańcucha danych na podstawie zadanego szeregu czasowego za pomocą algorytmu SAX.

4.1.1.3 JFreeChart

Biblioteka służąca do rysowania wykresów. Bardzo pomocna w początkowej fazie implementacji, kiedy autorowi zależało na zobrazowaniu przebiegu szeregów czasowych. Ich wizualizacja mogła przyczynić się do lepszego zrozumienia zależności między przebiegami, a diagnozą pacjenta.

4.1.1.4 Jxl

Dzięki pakietowi `jxl` w początkowej fazie implementacji autor mógł ściśle współpracować z arkuszami kalkulacyjnymi w celu raportowania danych do plików `.xls` w celu ich dalszej analizy statystycznej.

4.1.1.5 joda-time

W momencie gdy prace nad tą pracą dyplomową zostały rozpoczęte, wsparcie dla obiektów typu `data` czy `czas` było dla autora niewystarczające, dlatego zdecydowano się na wykorzystanie biblioteki `joda-time` w celu zapewnienia wymaganej obsługi tego rodzaju danych.

4.1.1.6 fast-dtw

Pakiet `fast-dtw` dostarcza obsługę obliczeniową dla eksperymentu bazującego na algorytmie Dynamic Time Warping, dzięki czemu autor mógł skorzystać z gotowego, przetestowanego i relatywnie wydajnego czasowo i pamięciowo rozwiązania dla tego celu.

4.1.1.7 apache-commons

W momentach gdy brakowało pewnych struktur danych w obecnej wersji Java - takich jak choćby `Pair` (ang. `para`) lub należało skorzystać z popularnych metod takich jak obliczenie regresji, korzystano z bibliotek `apache-commons`.

4.1.2 Punkt wyjścia

Praca programu zorientowana jest wokół obiektu `Workflow` (ang. „przepływ”, „proces”) - ma on na celu zdefiniowanie następujących po sobie kroków składających się na przebieg eksperymentu - począwszy od wczytania danych, aż do wypisania ostatecznego wyniku. Jego rdzeń zawiera się w abstrakcyjnej klasie `WorkflowBase` która posiada trzy główne metody - odpalenia przebiegu pełnego eksperymentu, wygenerowania pliku `arff` dla eksperymentu oraz wyliczenia wyniku eksperymentu dla zadanego pliku `arff`. Ponadto jest w stanie opisać podstawowe statystyki wczytanych danych, takie jak liczba klas decyzyjnych, podział instancji w klasach, czy liczba atrybutów w ramach instancji. Aby stworzyć własny eksperyment wystarczy stworzyć klasę dziedziczącą z `WorkflowBase` oraz zaimplementować wymagane metody. Przykładowy szkic takiej klasy przedstawiono na listingu 4.1: Jeżeli wczytane przez nas dane wymagają jakiegokolwiek ingerencji obliczeniowej - tak jak na przykład eksperyment `Counted`, to fragment kodu odpowiadający za te obliczenia powinien znaleźć się w metodzie `processData`. Jak widać w przywołanym listingu, wszystkie wymagane obliczenia odbywają się w tym fragmencie kodu. Kolejna metoda

Listing 4.1: Kod eksperymentu Counted

```
1 public class CountedWorkflow extends WorkflowBase {
2
3     private List<CalculatedRecord> calculatedRecords;
4
5     public CountedWorkflow(DivisionOptions divisionOption, boolean glaucoma) {
6         super(divisionOption, glaucoma);
7     }
8
9     @Override
10    protected Instances buildInstances() {
11        exporter = new CountedSaxArffBuilder(calculatedRecords);
12        return exporter.buildInstances();
13    }
14
15    @Override
16    protected void processData() throws Exception {
17        calculatedRecords = new ArrayList<CalculatedRecord>();
18
19        for (IRecord record : records) {
20            ArrayList<HashMap<String, Integer>> periodicallyCountedNgrams =
21                new ArrayList<HashMap<String, Integer>>();
22
23            List<String> dividedSax = DataDivider.divideStringRegularly(
24                record.getSaxString(), divisionPartsAmount);
25
26            for (String elem : dividedSax) {
27                HashMap<String, Integer> ngramCountMap = PeriodicNgramCounter
28                    .slashStringAndCountNgrams(elem, windowLen);
29                periodicallyCountedNgrams.add(ngramCountMap);
30            }
31
32            CalculatedRecord calcRecord = new CalculatedRecord(
33                periodicallyCountedNgrams, record.getDestinationClass());
34            calculatedRecords.add(calcRecord);
35        }
36    }
37
38    @Override
39    protected void setConcerningParams() {
40        concerningParameters.add(Pair.of("parts", divisionPartsAmount));
41        concerningParameters.add(Pair.of("ngram", windowLen));
42        concerningParameters.add(Pair.of("alpha", Config.getInstance().getSaxAlphabeatSize()));
43    }
44 }
```

to `buildInstances` która odpowiada za ustawienie odpowiedniego eksportera danych (w szczególności zostanie omówiony niżej) oraz przekazanie mu przeliczonych danych. Za jego pomocą tworzony jest obiekt `Instances`, który musi zostać zwrócony jako wynik metody. Funkcja `setConcerningParams` służy już tylko do tego, aby podczas wyświetlania wyniku eksperymentu wypisać, które parametry programu mają wpływ na pracę tego eksperymentu, oraz jakie ich wartości zostały ustawione podczas bieżącego wykonania.

4.1.3 Importowanie danych

Importowanie danych zostało rozdzielone ze względu na dwa różne formaty danych jakie potrafi wczytać program. Ostateczną wersją danych pacjentów jest opisanie danych każdego pacjenta w osobnym pliku `.csv`. W każdym z nich podany jest identyfikator pacjenta, oraz dane z poszczególnych pomiarów ciśnienia w oku. W ramach każdego pomiaru udostępnionych jest sporo danych, takich jak godzina o której pomiar został zdjęty, pozycja ciała w której znajdował się pacjent itp. choć na potrzebę tej pracy korzystano tylko z miary `TFADJ`. Jedyną informacją, której nie ma w tym pliku to diagnoza - ta opisana jest w pliku zbiorczym dla wszystkich pacjentów. W kolejnych wierszach znajdują się pary identyfikator pacjenta - diagnoza.

Drugim formatem, jaki wspiera program jest format danych prof. Eamonna. Ich charakterystyka jest prosta - każdy nowy wiersz w pliku to nowa instancja. W ramach każdego wiersza figurują atrybuty oddzielone spacjami, z których pierwszy to atrybut decyzyjny, a kolejne to szereg wartości składające się w szereg czasowy dla tej instancji. Tak jak wspomniano wcześniej, zapis ten pomija dokładny czas zebrania pomiaru. Klasy odpowiadające za wczytywanie danych to odpowiednio `PatientDataImporter2` oraz `DataImporterEamonn`.

4.1.4 Eksportowanie pliku `arff`

Jedną z funkcji programu jest wygenerowanie pliku `arff` w którym zapisane są już przetworzone dane o instancjach, gotowe do klasyfikacji klasyfikatorami `weki`. Aby stworzyć taki eksporter na własny użytek można posłużyć się klasą abstrakcyjną `ArffExporterBase` i rozszerzyć ją. Eksporter taki zostanie poniżej opisany na przykładzie `RegressionArffBuilder`. Jego kod można znaleźć na listingu 4.2. Klasa nadrzędna wymaga od programisty zaimplementowania dwóch metod oraz konstruktora.

Metoda `setAttributes` służy do tego aby nadać i nazwać atrybuty dla formatu danych jaki zdecydowano użyć w docelowym pliku `arff`. W pliku dla eksperymentu `Regression` tworzy się tyle par `slope-intercept` (współczynników a i b regresji) na ile części został podzielony sygnał. Należy również pamiętać o tym aby w liście atrybutów zawrzeć również atrybut decyzyjny.

W funkcji `buildInstances` programista musi obsłużyć przeniesienie danych ze struktury w jakiej trzymał dane po ewentualnych obliczeniach w metodzie `processData` klasy `WorkflowBase` do obiektu `Instances`. Dzięki temu umożliwione będzie wygodne eksportowanie pliku `arff` oraz przeprowadzanie eksperymentu za pomocą klasy `Evaluation`. Ostatnią rzeczą o którą trzeba zadbać, to wywołanie metod `setDestinationClasses` oraz `setAttributes` w konstruktorze tak jak pokazano na wspomnianym listingu.

Listing 4.2: Kod eksportera dla eksperymentu `Regression`

```

1  public class RegressionArffBuilder extends ArffExporterBase {
2
3      private List<RegressionRow> input;
4
5      public RegressionArffBuilder(List<RegressionRow> input) {
6          this.input = input;
7          setDestinationClasses(input);
8          setAttributes();
9      }
10
11     protected void setAttributes() {
12         attrInfo = new FastVector();
13
14         int regressionCount = input.stream().findFirst().get()
15             .getRegressionResults().size();
16
17         for (int i = 0; i < regressionCount; i++) {
18             attrInfo.addElement(new Attribute(String.format("slope%d", i + 1)));
19             attrInfo.addElement(new Attribute(String.format("intercept%d",
20                 i + 1)));
21         }
22
23         Attribute destClassAttribute = null;
24         try {
25             destClassAttribute = constructDestinationClassesNominalAttribute(destClasses);
26         } catch (Exception e) {
27             e.printStackTrace();
28         }
29         attrInfo.addElement(destClassAttribute);
30     }
31
32     @Override
33     public Instances buildInstances() {
34         instances = new Instances("Regression", attrInfo, input.size());
35         instances.setClassIndex(instances.numAttributes() - 1);
36
37         for (RegressionRow row : input) {
38             Instance instance = new Instance(attrInfo.size());
39             int attrIdx = 0;
40             for (RegressionResult regResult : row.getRegressionResults()) {
41                 instance.setValue(attrIdx++, regResult.getSlope());
42                 instance.setValue(attrIdx++, regResult.getIntercept());
43             }
44
45             int destClassIndex = getIndexOfDestinationClass(row
46                 .getDestinationClass());
47             instance.setValue(attrIdx, destClassIndex);
48             instances.add(instance);
49         }
50         return instances;
51     }

```

52 }

4.2 Serwisy zewnętrzne

4.2.1 Git

Dla zapewnienia jak najwyższej jakości kodu oraz niezawodnego dostępu do niego, używano systemu kontroli wersji, który był dostarczany przez oprogramowanie **git**. Dzięki darmowym serwisom udostępniającym swoje serwery na potrzeby wersjonowania źródeł, takim jak **gitlab.com** zapewnione było bezpieczeństwo danych, a także wspólny dostęp do postępów prac zarówno przez autora, jak i promotora. Na potrzeby obsługi tego narzędzia użyto oprogramowania **SourceTree**, które wyraźnie ułatwia i przyspiesza pracę z systemem **git**.

4.2.2 Travis

Portal **travis.com** jest to serwis Continuous Integration ściśle współpracujący z opisanym wyżej **gitlab.com**. Jego zadaniem jest sprawdzanie każdej kolejnej udostępnionej wersji kodu na serwerze. W momencie gdy pojawia się jego nowa wersja, Travis kompiluje świeżo pobrany kod, uruchamia wszystkie zamieszczone w kodzie testy i ocenia tzw. 'build' pozytywnie lub negatywnie. Dzięki organizacji pracy z takim serwisem Continuous Integration i pokryciu kluczowych obliczeniowych metod testami, wyłapano wiele błędów implementacyjnych we wczesnym ich etapie.

Wnioski

5.1 Analiza wyników - część podstawowa

Gdy nadszedł czas na analizę wyników, dla uproszczenia porównań postanowiono wybrać najlepsze wyniki dla każdego z eksperymentów, a dopiero wówczas przeanalizować je bliżej. Aby wyłuskać najskuteczniejsze zestawy parametrów dla każdego z nich posłużono się prostym zliczeniem zbiorów na których dany zestaw był najlepszy. Po tym kroku zostały wybrane następujące uruchomienia:


- Zliczanie - części: 5, ngram: 2, alfabet: 11
- Regresja - części: 10
- Klasyfikator ngramowy - ngram: 30, alfabet: 3
- DTW - knn: 7, szerokość okna DTW: 5
- KNN - ngram: 3, alfabet: 11, knn: 3
- Bagging - części: 5, ngram: 3, alfabet: 5 (na 20% przykładów)

Każdy z nich przeprowadzony został z użyciem pięciokrotnej krosvalidacji powtórzonej trzy razy.

Ze względu na to, że uśrednianie wyników ze wszystkich zbiorów może być zgubne, postanowiono choć kilkoma słowami opisać wynik na każdym z badanych zbiorów.


ECG200

Dość mały zbiór z relatywnie krótkim szeregiem do przeanalizowania. W kwestii dokładności klasyfikacji widać zdecydowaną dominację podejścia *KNN SAX*, któremu zbiór wyraźnie odpowiadał. Nieco niżej, na podobnym poziomie dokładności, uplasowały się metody *C4.5 regression* oraz *DTW raw*. Najgorzej z tymi danymi poradziły sobie warianty *C4.5 ngrams*, *Basic ngrams* oraz *C4.5 bagging ngrams*. Zły wynik *Basic ngrams* nie zaskakuje - bo jak się okaże niebawem na większości zbiorów nie wypadł dobrze, jednak poza tym widać, że algorytmy zliczeniowe nie byłyby dla takiego zbioru najlepszym wyborem.



Rysunek 5.1: Dokładność eksperymentów na zbiorze ECG200

ECGFiveDays




Rysunek 5.2: Dokładność eksperymentów na zbiorze ECGFiveDays

Wydaje się, że dość prosty w klasyfikacji zbiór danych - wszystkie klasyfikacje za wyjątkiem *Basic ngrams* (choć na tę metodę patrzono z przymrużeniem oka ze względu na kiepskie wyniki na większości zbiorów) zanotowały znakomitą dokładność w przyporządkowywaniu instancji do klas. Co cieszy, to fakt, że znów najlepiej poradził sobie algorytm *KNN SAX* śrubując wynik aż na 99% poprawnie sklasyfikowanych przypadków.

TwoLeadECG


Podobnie jak w powyższym zbiorze danych, w *TwoLeadECG* wszystkie klasyfikatory za wyjątkiem *Basic ngrams* wypadły bardzo dobrze, jednak tym razem najlepszym z nich okazał się *DTW raw* - choć jak wspomniano w części teoretycznej - wyniki z tego podejścia zestawione są raczej w celach porównawczych, biorąc pod uwagę fakt, że czas spędzony na



Rysunek 5.3: Dokładność eksperymentów na zbiorze TwoLeadECG

przetwarzanie jest nieporównywalnie dłuższy niż w pozostałych przypadkach. Pomijając zatem ten algorytm, najlepszą lokatę znów zajmuje *KNN SAX*.

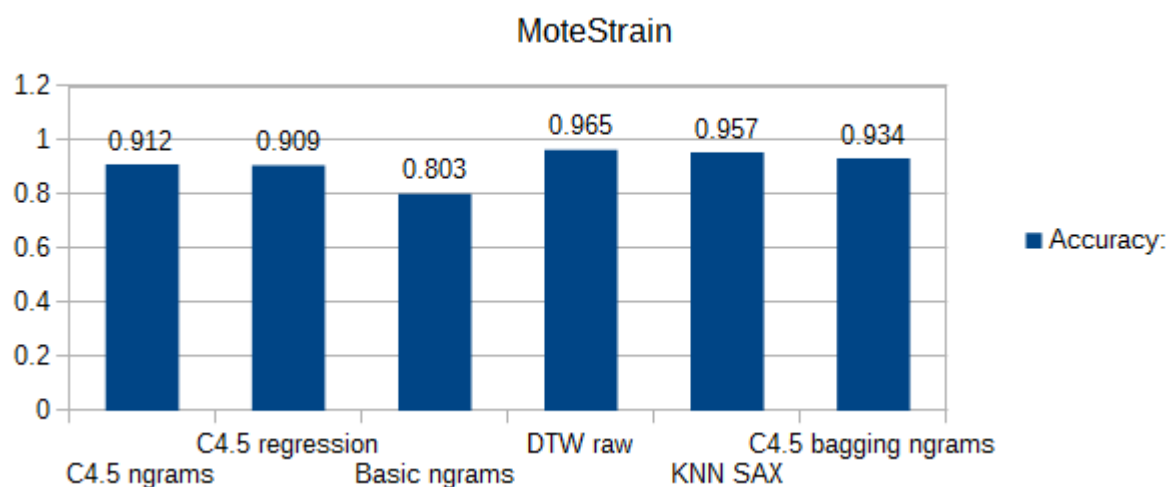
Yoga




Rysunek 5.4: Dokładność eksperymentów na zbiorze Yoga

Yoga nie jest już tak prostym zbiorem jak jej dwaj poprzednicy. Zbiór ma 3300 instancji oraz charakteryzuje się długością szeregu 426. Poziom skomplikowania odzwierciedla się na wynikach - tym razem dokładności klasyfikacji rozpościerają się w przedziale 0.667 – 0.924. Znow najlepszymi wynikami pochwalić się mogą dwa wiodące dotąd klasyfikacje - czyli odpowiednio *KNN SAX* oraz *DTW raw*. Pozostałe podejścia (oprócz *Basic ngrams*) odnotowały wynik na bardzo podobnym poziomie.

MoteStrain oraz ItalyPowerDemand



Rysunek 5.5: Dokładność eksperymentów na zbiorze MoteStrain




Rysunek 5.6: Dokładność eksperymentów na zbiorze ItalyPowerDemand

Dwa podobne pod względem wyników, jak i liczby instancji, zbiory. Choć długość szeregu wyraźnie różna - odpowiednio 84 i 24. Wszystkie podejścia wypadły zadowalająco, *Basic ngrams* wyjątkowo nie odstawał odczuwalnie od pozostałych. Tak jak dotychczas, czołówka pozostała ta sama - *DTW raw* oraz *KNN SAX*.


ChlorineConcentration

Pierwszy z wieloklasowych zbiorów i również pierwsza zmiana lidera - w tym przypadku na tle innych najlepszą dokładność uzyskała regresja *ex aequo* z *DTW raw*. Warto odnotować, że w porównaniu do pozostałych, jest to duży zbiór (4307 instancji), a mimo to, tak prosta ideowo koncepcja jak regresja okazała się być najlepszym wyborem, co na pewno jest pewnego rodzaju ciekawostką.



Rysunek 5.7: Dokładność eksperymentów na zbiorze ChlorineConcentration

TwoPatterns




Rysunek 5.8: Dokładność eksperymentów na zbiorze TwoPatterns

Kolejny 'sensacyjny' zbiór - tym razem dlatego, że wariantowi *DTW raw* udało się uzyskać stuprocentową skuteczność, czym zdeklasował swoich konkurentów. Podobny wynik (aż 99%) odnotował *KNN SAX*, nieco gorzej *C4.5 bagging ngrams*, a już wyraźnie gorzej (choć wciąż nienagannie) pozostałe algorytmy. Jest to jeden z największych zbiorów w tej analizie (5000 instancji) z dość długim szeregiem - 128 wartościami, a także aż czterema klasami, co tym bardziej podkreśla znakomity wynik wiodących metod klasyfikacji.

Wafer


Znowu doskonała dokładność algorytmu *KNN SAX* który otarł się o maksymalną jej możliwą wartość. Pozostałe podejścia - za wyjątkiem *Basic ngrams* odnotowały równie dobry wynik - bliski lub nawet przekraczający 99%. Niestety *Basic ngrams* aż 11% niżej w tym



Rysunek 5.9: Dokładność eksperymentów na zbiorze Wafer

zestawieniu.

InlineSkate




Rysunek 5.10: Dokładność eksperymentów na zbiorze InlineSkate

Tym razem otrzymano trochę bardziej różnorodne wyniki niż w poprzedzających przypadkach. Nie licząc *DTW raw*, najlepszy tym razem okazał się *C4.5 bagging ngrams* z wynikiem 84%. Dalej kolejno *KNN SAX*, *C4.5 regression* oraz *C4.5 ngrams*. Jak w każdym z ubiegłych wyników *Basic ngrams* zamyka stawkę - tym razem z wynikiem 79.3%

Pacjenci

Na sam koniec słowo o zbiorze *Pacjentów*, który na tle pozostałych zbiorów wypadł zaskakująco słabo - na wszystkich analizowanych metodach. Nieoczekiwanie najlepszym



Rysunek 5.11: Dokładność eksperymentów na zbiorze Pacjentów

wynikiem może się pochwalić klasyfikator *Basic ngrams*, choć ten wynik po serii niepowodzeń raczej uznano za przypadek niż faktyczne dostosowanie algorytmu do charakterystyki danych. Na pewno nie jest przypadkiem fakt, że żadne z podejść nie potrafiło poradzić sobie ze zbiorem z przyzwoitą dokładnością. Najprawdopodobniej szeregi te na obu klasach są relatywnie jednorodne, przez co klasyfikatorom łatwo pomylić osobę chorą ze zdrową.

Podsumowanie

Podsumowując powyższe krótkie analizy wyników eksperymentów na poszczególnych zbiorach danych, widać gołym okiem, że najskuteczniejszym podejściem okazał się algorytm *KNN SAX*, odnotowujący najlepszy lub prawie najlepszy wynik na każdym z nich. Nie bierzemy pod uwagę równie dobrze wypadającego *DTW raw* ze względu na zbyt długie obliczenia przeprowadzane podczas klasyfikowania instancji. Tak dobry wynik *KNN SAX* jest o tyle satysfakcjonujący dla autora, że ściśle bazuje na metodzie, którą wybrano już na początku realizacji tej pracy, a mianowicie metody SAX.

Niestety zawiódł autorski klasyfikator ngramowy, lecz jego koncept działania nie był mocno wyszukany, więc jego niska dokładność nie jest rozczarowaniem.

Z drugiej strony jednak prosta idea nie jest przeszkodą do zdobywania dobrych wyników - czego potwierdzeniem jest znakomity wynik regresji - tutaj wprawdzie nieco zmniejszonej, bo była ona liczona bowiem wielokrotnie dla kolejnych części sygnału w ramach każdej instancji - jednak nadal u podstaw leży nieskomplikowana estymacja danych do funkcji liniowej.

Powstaje pytanie dlaczego skupiono się tylko na mierze dokładności, skoro w większości przypadków badano aż sześć miar. Otóż jak się okazuje, wyniki wszystkich miar w większości eksperymentów (szczególnie w tych dwuklasowych) są do siebie bardzo zbliżone. Obliczono, że odchylenie standardowe miar eksperymentów na zbiorach *ECG200*, *ECG-FiveDays*, *TwoLeadEcg*, *Yoga*, *MoteStrain*, *ItalyPowerDemand*, *Wafer*, oraz *Patients* jest mniejsze od 0.05. Pozostałe zbiory (*ChlorineConcentration*, *TwoPatterns*, *InlineSkate*) to zbiory wieloklasowe na których zróżnicowanie miar było bardziej wyraźne.

Ostatecznie zatem wyniki są zadowalające dzięki eksperymentowi KNN, który nieznacznie odstępuje kroku w jakości wobec matematycznie skomplikowanego DTW, a zdecydowanie deklasuje go w kontekście czasu przetwarzania. Największą zagadką był klasyfikator ngramowy, którego model działania powstał na bazie pomysłu autora, jednak jego rezultaty nie okazały się miłą niespodzianką - jedynie potwierdziły, że stworzenie dobrego klasyfikatora nie jest prostym zadaniem.

5.2 Analiza wyników - część rozszerzona

Po udanej ewaluacji założonych eksperymentów postanowiono rozszerzyć nieco zakres tej pracy i przetestować zdolności algorytmu bazującego na zbiorach reguł decyzyjnych - a mianowicie na klasyfikatorze VC-DomLEM. Ze względu na ograniczenia techniczne i czasowe nie uzyskano wyników dla wszystkich dostępnych zbiorów, lecz badana część była wystarczająca aby dostarczyć interesujących informacji.

Tym razem skupiono się na eksperymentach regresyjnym (*VC-DomLEM bagging regression*) i zdominowanym (*VC-DomLEM bagging ngrams*). Podobnie jak poprzednim razem, ze względu na bardzo zbliżone wyniki na wszystkich miarach, zdecydowano się na analizę miary dokładności. Dzięki temu też łatwiej będzie się odnieść do wyników z części podstawowej. Ponadto dla uproszczenia porównań skupiono się na subiektywnie najlepszych uruchomieniach tego eksperymentu. Były to:

- Zliczanie zdominowane - części: 5, ngram: 2, alfabet: 11
- Regresja - części: 20


Należy również wspomnieć, że klasyfikator ten ze względu na zbyt dużą ilość czasu przetwarzania, został ustawiony tak, by uczył się tylko na 20% części danych. Każdy z eksperymentów używał na swoje potrzeby dziesięciu niezależnie stworzonych klasyfikatorów (każdy z nich tworzył swoje reguły), a przyporządkowania ustalano za pomocą głosowania.

ECGFiveDays oraz TwoLeadECG


Pierwszy wynik eksperymentów z tej części wyszedł obiecująco - dokładność na poziomie 96%-98% jest bardzo przyzwoita i utrzymuje się na tym samym poziomie co w części pierwszej badania. W ECGFiveDays lepszy okazał się eksperyment zdominowanego zliczania ngramów, a w drugim zbiorze lepsza okazała się być regresja. Wprawdzie zestawiając wszystkie wyniki, *DTW raw* okazałby się podejściem najlepszym, lecz o nim już wspomniano, że jest eksperymentem bardziej referencyjnym niż współzawodniczącym. Zatem w tym wypadku nowe podejście do testowania nie polepszyło rezultatów, jednak dorównanie tak dobremu wynikowi ubiegłych ewaluacji można już uznać za sukces.

MoteStrain


Stabilny zbiór - wypadł niemalże tak samo na obu eksperymentach. Swoją niewielką przewagę tym razem zademonstrowało podejście zdominowane, jednak jego wynik w odniesieniu do doświadczeń z ubiegłej części wypadł przeciętnie - choć ponownie, wynik na poziomie powyżej 90% można uznać za dobry.



Rysunek 5.12: VC-DomLEM dla ECGFiveDays




Rysunek 5.13: VC-DomLEM dla TwoLeadECG



Rysunek 5.14: VC-DomLEM dla MoteStrain


ItalyPowerDemand



Rysunek 5.15: VC-DomLEM dla ItalyPowerDemand

Zbiór ItalyPowerDemand poróżnił nieco badane eksperymenty - widać wyraźną amplitudę pomiędzy wartościami ich dokładności. Wariant zdominowany wypadł zdecydowanie lepiej niż jego regresyjny rywal. Sam wynik robi wrażenie - 96% dokładność w zestawieniu z części podstawowej zapewniłaby czołówkę rankingu.


ChlorineConcentration



Rysunek 5.16: VC-DomLEM dla ChlorineConcentration

Wyniki *ChlorineConcentration* pozwalają sądzić, że dla tego zbioru klasyfikator *VC-DomLEM* nie był najtrafniejszym wyborem - rezultaty sięgające 70% są poniżej oczekiwań, biorąc pod uwagę to, że dotychczas klasyfikator *VC-DomLEM* radził sobie tak samo dobrze jak te z części podstawowej.

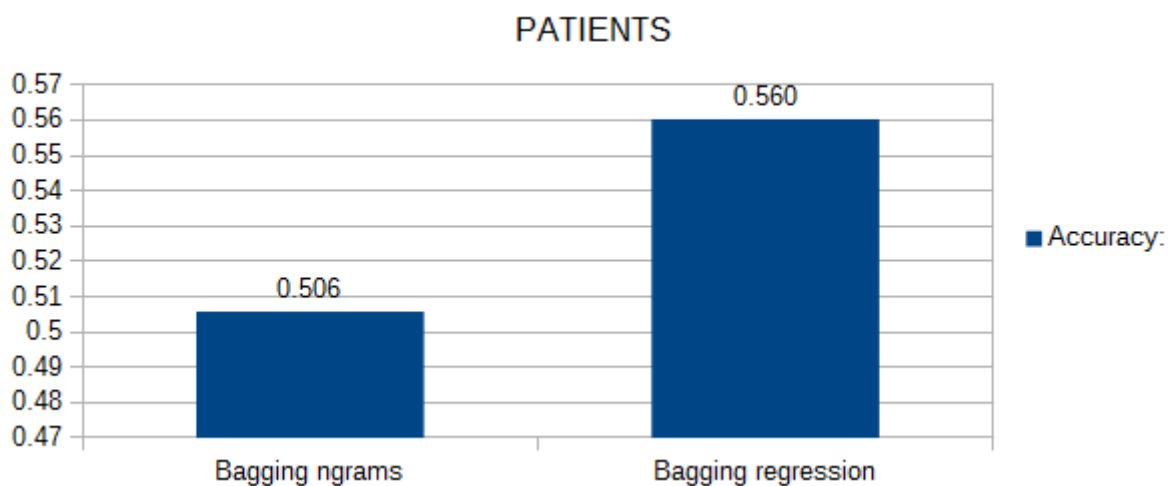
InlineSkate



Rysunek 5.17: VC-DomLEM dla InlineSkate

Największe rozczarowanie tego badania - niestety wyniki niemal dwukrotnie mniejsze niż ich odpowiedniki z podstawowej części. Jednakże pamiętać należy że jest to zbiór z największą liczbą klas (7) i niezbyt dużym zbiorem instancji (650), a także klasyfikatorem uczącym się tylko na 20% zbiorze - te argumenty są w stanie w pewnym stopniu usprawiedliwić taki rezultat.

Pacjenci



Rysunek 5.18: VC-DomLEM dla Pacjentów

W zbiorze danych Pacjentów lepiej poradził sobie wariant regresyjny - którego wynik na przestrzeni innych podejść jest w pełni zadowalający. Pamiętać należy, że zbiór ten był dość trudny - poprzednie uruchomienia osiągały tutaj wyniki w granicach 50% zatem

rezultat przekraczający 56% sprowadza podejście do klasyfikacji danych z niniejszej części na dobre tory.

Posumowanie

Jak zauważono podczas analizy poszczególnych zbiorów, eksperymenty korzystające z klasyfikatora *VC-DomLEM* prowadzą niekiedy do lepszych wyników od poprzedników, jednak na danych dostępnych w niniejszej pracy zademonstrowały nieco mniejszą stabilność działania. Miało to miejsce choćby przypadku *InlineSkate* - lecz jak wspomniano może to być wina charakterystyki zbioru.

Badane podejście zbioru reguł decyzyjnych na pewno ma duży potencjał, jednak przy obranym kierunku tworzenia danych wejściowych dla eksperymentu, niekorzystny stosunek liczby atrybutów do liczby instancji na pewno niekorzystnie odbił się na podejściu regułowym. Zatem mimo drobnych niepowodzeń można uznać to podejście za równie dobre odpowiednikiem z pierwszej części eksperymentu.

5.3 Podsumowanie

W ostatecznym rozrachunku wykonano sześć początkowo założonych eksperymentów na jedenastu zbiorach, oraz dwa eksperymenty rozszerzające na niektórych z nich. W wersji podstawowej do pracy zaprzęgnięto klasyczną metodę regresji, algorytm *KNN*, dość nowatorskie podejścia przetwarzania danych algorytmem *SAX*, a także w ramach referencji posłużono się algorytmem *DTW*.

Mimo że liczba zbiorów nie była przesadnie liczna, dobrany zestaw zbiorów był na tyle różnorodny, że dostarczał zbiory zarówno z małą i dużą liczbą instancji jak i atrybutów. Zapewnił również zbiory dwu- oraz wieloklasowe.

Właściwe eksperymenty również nie skupiały się tylko na przesyłaniu danych klasyfikatorom. Ich przetwarzanie w wielu przypadkach można uznać za dwuetapowe - etap wstępnej obróbki danych, a dopiero potem - klasyfikacji.

Zestaw użytych klasyfikatorów również był urozmaicony - zastosowano klasyfikatory pakietu *weka*: *J48*, *IBk*, meta-klasyfikator agregujący *Bagging*, a także klasyfikatora implementującego algorytm *VC-DomLEM*. Pokuszono się również o stworzenie autorskiego klasyfikatora, bazującego na danych zwróconych przez algorytm *SAX*. Mimo że nie spodziewano się rewelacyjnych wyników, to jego nie najlepsze wyniki były okazały się dla autora drobnym zawodem.

W ostatnim etapie przeprowadzania badań zdecydowano się na stworzenie środowiska dla uruchomienia kolejnych eksperymentów - tym razem z podejściem dominacyjnym. Na pierwszy rzut oka wyniki te nie wprowadziły widocznego postępu wobec swoich poprzedników. Jednak należy pamiętać, że ze względu na ograniczający autora czas, mają one raczej charakter wstępny. Starając się zmniejszyć czas uczenia zdecydowano się, podobnie jak we wcześniejszych eksperymentach z baggingiem, zmniejszyć wielkość zbiorów uczących każdego z klasyfikatorów składowych. W eksperymentach tych uczenie przeprowadzono na próbkach bootstrapowych stanowiących jedynie 20% przykładów z oryginalnego zbioru uczącego. Podejście dominacyjne drastycznie zwiększa liczbę atrybutów (czterokrotnie w

porównaniu do innych) - co na pewno miało wpływ na wyniki w mniejszych lub wieloklasowych zbiorach (gdzie przypadało mało instancji na klasę).

Biorąc pod uwagę opisane powyżej problemy, w kolejnym kroku można by rozważyć podejście *Attribute Bagging*[\[6\]](#) do istniejących rozwiązań dominacyjnych. Pozwoliłoby to na znaczne uszczuplenie liczby atrybutów, co powinno przełożyć się na inne wyniki niż dotychczasowe.

Podręcznik użytkownika

Dla przejrzystości tego rozdziału przyjęto, że materiały z płyty zostały rozpakowane do ścieżki **D:/TimeSeries/**.

A.1 Uruchomienie projektu w środowisku Eclipse

Projekt programu rozwijany był na środowisku deweloperskim Eclipse Mars, wersja 'Java Developers', na systemie Windows. Projekt zbudowany jest według koncepcji narzędzia Maven, dlatego przy wgrywaniu go do Eclipse należy użyć opcji **File->Import->Existing Maven Project**. Po tym kroku projekt powinien być w stanie bezbłędnie się uruchomić.

A.2 Uruchomienie programu z linii komend

Wraz z kodem źródłowym projektu został dostarczony również wykonywalny plik **.jar** pozwalający na uruchomienie programu bez potrzeby instalacji środowiska deweloperskiego i kompilowania kodu. By przeprowadzić ten proces, należy upewnić się, że dane, które planuje się przetworzyć zlokalizowane są w folderze **/data** w stosunku do pliku wykonywalnego. Nie należy zmieniać drzewa folderów w tej ścieżce.

Przed uruchomieniem programu trzeba sprecyzować jaki wariant eksperymentu zamierza się uruchomić (właściwość **variant**). W przypadku importowania istniejącego pliku arff należy podać dokładną ścieżkę do pliku we właściwości **inputArffPath**. Następnie należy wybrać zbiór danych na jakim eksperyment będzie działał - odpowiada za to właściwość **targetDataset**. Ostatnim parametrem jaki należy doprecyzować w pliku konfiguracyjnym jest rodzaj eksperymentu jaki się uruchomi, sterowanym właściwością **experimentId**. Przykładowy pełny plik konfiguracyjny z podanymi możliwymi wartościami na poszczególnych właściwościach w komentarzach przedstawiono na listingu A.1. Po dostosowaniu parametrów do potrzeb, można przejść do uruchomienia programu. Potrzebna będzie do tego linia komend, w której należy przejść do ścieżki bazowej **D:/TimeSeries**. Z tego miejsca należy wydać polecenie **java -jar timeseries.jar** i oczekiwać na wyniki. Dla wygody można przekierować wynik przetwarzania do pliku dodając do ubiegłego polecenia **>output.txt**.

Listing A.1: config.properties - plik konfiguracyjny

```

#paths
dataFolderPath = data/
glaucomaDataSet = dataset glaucoma/

# --- Experiment variables ---

# 1, 3, 5 - for regression additionally: 10,20,48
divisionPartsAmount = 3
#2, 3
ngramSize = 3
#3, 5, 11
saxAlphabeatSize = 5

#3, 5, 7
k = 7

dtwSearchRadius = 3

#-----

# --- Target job variant
# 0:ARFFEXPORT 1:ARFFPROCESS 2:FULL
variant = 2

# --- Arff path - file which will be used to run experiment on
# (needed only if variant=1 was picked)
inputArffPath = output/arffOutput/NGRAM/NGRAM for ECGFIVEDAYS with ngram-3 alpha-4.arff

# --- Target dataset - the one which experiment would be launched with
# 0:ECG200 1:ECGFIVEDAYS 2:SAMPLEUNITTEST 3:TWOLEADECG 4:YOGA 5:MOTESTRAIN
# 6:ITALYPOWERDEMAND 7:CHLORINECONCENTRATION 8:TWOPATTERNS 9:WAFER
# 10:INLINESKATE 11:PATIENTS
# -1: run experiment for all datasets (except sample unit test one)
targetDataset = -1

# --- Experiments
# 0:REGRESSION 1:DOMINANT 2:COUNTEDED 3:NGRAM 4:KNN 5:DTW 6:BAGGING
experimentId = 6

# --- 'constants'
saxOutputLength = 96
crossValidationRepetitions =3
crossValidationFolds = 5

```

Wyniki

B.1 Wyniki dla najlepszych zestawów parametrów w ramach eksperymentu

B.1.1 Eksperymenty Zliczania, Regresji oraz Ngram

	COUNTED	REGRESSION	NGRAM
	parts: 5 ngram: 2 alpha: 11	parts: 10	ngram: 30, alpha: 3
Ecg200			
Accuracy:	0.8	0.831667	0.788333
F1 score:	0.798164	0.832295	0.806472
Sensitivity:	0.8	0.831667	0.788333
Specificity:	0.726428	0.784351	0.831649
G-Mean:	0.762291	0.807543	0.809701
PCC:	0.8	0.831667	0.788333
EcgFiveDays			
Accuracy:	0.940422	0.947964	0.837858
F1 score:	0.940479	0.947991	0.839159
Sensitivity:	0.940422	0.947964	0.837858
Specificity:	0.940422	0.947964	0.837858
G-Mean:	0.940422	0.947964	0.837858
PCC:	0.940422	0.947964	0.837858
TwoLeadEcg			
Accuracy:	0.919679	0.965863	0.654045
F1 score:	0.919715	0.965893	0.657586
Sensitivity:	0.919679	0.965863	0.654045
Specificity:	0.919679	0.965863	0.654045

	COUNTED	REGRESSION	NGRAM
G-Mean:	0.919679	0.965863	0.654045
PCC:	0.919679	0.965863	0.654045
Yoga			
Accuracy:	0.825556	0.866465	0.66697
F1 score:	0.825509	0.86646	0.677264
Sensitivity:	0.825556	0.866465	0.66697
Specificity:	0.822888	0.864513	0.63464
G-Mean:	0.824221	0.865488	0.650604
PCC:	0.825556	0.866465	0.66697
MoteStrain			
Accuracy:	0.911688	0.908805	0.802673
F1 score:	0.911702	0.90896	0.807601
Sensitivity:	0.911688	0.908805	0.802673
Specificity:	0.910592	0.909097	0.784759
G-Mean:	0.91114	0.908951	0.793665
PCC:	0.911688	0.908805	0.802673
ItalyPowerDemand			
Accuracy:	0.935219	0.956204	0.809915
F1 score:	0.935256	0.956214	0.810781
Sensitivity:	0.935219	0.956204	0.809915
Specificity:	0.935195	0.956211	0.809777
G-Mean:	0.935207	0.956208	0.809846
PCC:	0.935219	0.956204	0.809915
ChlorineConcentration			
Accuracy:	0.826845	0.88004	0.650698
F1 score:	0.739366	0.819871	0.51047
Sensitivity:	0	0	0
Specificity:	0	0	0
G-Mean:	0	0	0
PCC:	0.740268	0.82006	0.476047
Two patterns			
Accuracy:	0.869533	0.892267	0.7497
F1 score:	0.738998	0.784576	0.485512
Sensitivity:	0	0	0
Specificity:	0	0	0
G-Mean:	0	0	0
PCC:	0.739067	0.784533	0.4994
Wafer			

	COUNTED	REGRESSION	NGRAM
Accuracy:	0.988089	0.995021	0.881863
F1 score:	0.988027	0.99503	0.848667
Sensitivity:	0.988089	0.995021	0.881863
Specificity:	0.928058	0.980909	0.130399
G-Mean:	0.957603	0.987939	0.339108
PCC:	0.988089	0.995021	0.881863
Inlineskate			
Accuracy:	0.825495	0.828425	0.793114
F1 score:	0.390692	0.399968	0.294736
Sensitivity:	0	0	0
Specificity:	0	0	0
G-Mean:	0	0	0
PCC:	0.389231	0.399487	0.275897
Pacjenci			
Accuracy:	0.58046	0.491379	0.58908
F1 score:	0.578826	0.494797	0.591326
Sensitivity:	0.58046	0.491379	0.58908
Specificity:	0.559611	0.491124	0.586083
G-Mean:	0.569931	0.491162	0.587569
PCC:	0.58046	0.491379	0.58908

B.1.2 Eksperymenty DTW, KNN oraz Bagging

	DTW	KNN	BAGGING
	Knn: 7, DtwWin: 5	ngram: 3, alpha: 11, knn: 3,	parts: 5, ngram: 3, alpha: 5,
Ecg200			
Accuracy:	0.833333	0.895	0.803333
F1 score:	0.833177	0.895075	0.801476
Sensitivity:	0.833333	0.895	0.803333
Specificity:	0.733345	0.836007	0.713294
G-Mean:	0.781733	0.864989	0.756963
PCC:	0.833333	0.895	0.803333
EcgFiveDays			
Accuracy:	0.977753	0.99095	0.970588
F1 score:	0.977922	0.990986	0.970603
Sensitivity:	0.977753	0.99095	0.970588
Specificity:	0.977753	0.99095	0.970588

	DTW	KNN	BAGGING
G-Mean:	0.977753	0.99095	0.970588
PCC:	0.977753	0.99095	0.970588
TwoLeadEcg			
Accuracy:	0.997992	0.968445	0.911933
F1 score:	0.997996	0.968446	0.911954
Sensitivity:	0.997992	0.968445	0.911933
Specificity:	0.997992	0.968445	0.911933
G-Mean:	0.997992	0.968445	0.911933
PCC:	0.997992	0.968445	0.911933
Yoga			
Accuracy:	0.912929	0.924141	0.853333
F1 score:	0.913188	0.924337	0.853572
Sensitivity:	0.912929	0.924141	0.853333
Specificity:	0.908872	0.920632	0.847904
G-Mean:	0.910898	0.922385	0.850614
PCC:	0.912929	0.924141	0.853333
MoteStrain			
Accuracy:	0.964885	0.956761	0.934224
F1 score:	0.96496	0.956786	0.934682
Sensitivity:	0.964885	0.956761	0.934224
Specificity:	0.962841	0.95531	0.936567
G-Mean:	0.963862	0.956035	0.935395
PCC:	0.964885	0.956761	0.934224
ItalyPowerDemand			
Accuracy:	0.958029	0.965328	0.941606
F1 score:	0.958245	0.965334	0.941619
Sensitivity:	0.958029	0.965328	0.941606
Specificity:	0.958084	0.965326	0.941592
G-Mean:	0.958057	0.965327	0.941599
PCC:	0.958029	0.965328	0.941606
ChlorineConcentration			
Accuracy:	0.880143	0.854191	0.764569
F1 score:	0.820249	0.78145	0.656575
Sensitivity:	0	0	0
Specificity:	0	0	0
G-Mean:	0	0	0
PCC:	0.820215	0.781286	0.646854
Two patterns			

	DTW	KNN	BAGGING
Accuracy:	1	0.989933	0.971367
F1 score:	1	0.979885	0.943337
Sensitivity:	0	0	0
Specificity:	0	0	0
G-Mean:	0	0	0
PCC:	1	0.979867	0.942733
Wafer			
Accuracy:	0.992323	0.998325	0.983482
F1 score:	0.992298	0.998334	0.983363
Sensitivity:	0.992323	0.998325	0.983482
Specificity:	0.955538	0.998259	0.896679
G-Mean:	0.973756	0.998292	0.939078
PCC:	0.992323	0.998325	0.983482
Inlineskate			
Accuracy:	0.856264	0.834725	0.839853
F1 score:	0.503696	0.434377	0.440057
Sensitivity:	0	0	0
Specificity:	0	0	0
G-Mean:	0	0	0
PCC:	0.496923	0.421538	0.439487
Pacjenci			
Accuracy:	0.554598	0.422414	0.534483
F1 score:	0.553333	0.424105	0.525399
Sensitivity:	0.554598	0.422414	0.534483
Specificity:	0.535096	0.411674	0.475673
G-Mean:	0.544758	0.417008	0.504145
PCC:	0.554598	0.422414	0.534483

B.1.3 Eksperymenty używające klasyfikatora VC-DomLEM

	VC-DomLEM bagging ngrams	VC-DomLEM bagging regression
	parts: 5, ngram: 2, alpha: 11	parts: 20
EcgFiveDays		
Accuracy:	0.975867	0.962293
F1 score:	0.975685	0.962985

	VC-DomLEM bagging ngrams	VC-DomLEM bagging regression
Sensitivity:	0.968326	0.981146
Specificity:	0.983409	0.943439
G-Mean:	0.975838	0.962108
PCC:	0.975867	0.962293
TwoLeadECG		
Accuracy:	0.969306	0.978199
F1 score:	0.969437	0.978396
Sensitivity:	0.973609	0.987378
Specificity:	0.965003	0.969019
G-Mean:	0.969296	0.978155
PCC:	0.969306	0.978199
MoteStrain		
Accuracy:	0.939465	0.930031
F1 score:	0.94073	0.932633
Sensitivity:	0.949461	0.949461
Specificity:	0.9309	0.913382
G-Mean:	0.940135	0.931247
PCC:	0.939465	0.930031
ItalyPowerDemand		
Accuracy:	0.958637	0.85371
F1 score:	0.958423	0.859614
Sensitivity:	0.953687	0.895186
Specificity:	0.96357	0.812386
G-Mean:	0.958616	0.852782
PCC:	0.958637	0.85371
ChlorineConcentration		
Accuracy:	0.652787	0.716121
F1 score:	0.682798	0.733842
Sensitivity:	0	0
Specificity:	0	0
G-Mean:	0	0
PCC:	0.652787	0.716121
InlineSkate		
Accuracy:	0.477802	0.496923
F1 score:	0.519019	0.545582
Sensitivity:	0	0

	VC-DomLEM bagging ngrams	VC-DomLEM bagging regression
Specificity:	0	0
G-Mean:	0	0
PCC:	0.477802	0.496923
Pacjenci		
Accuracy:	0.505747	0.560345
F1 score:	0.511523	0.579887
Sensitivity:	0.533333	0.620513
Specificity:	0.470588	0.48366
G-Mean:	0.500979	0.54783
PCC:	0.505747	0.560345

Bibliografia

- [1] Opis przeprowadzenia algorytmu paa w bibliotece jmotif. http://jmotif.github.io/sax-vsm_site/morea/algorithm/PAA.html. Ostatni dostęp: 2015-09-26.
- [2] Wzór na odchylenie standardowe. https://en.wikipedia.org/wiki/Standard_deviation#Rapid_calculation_methods. Ostatni dostęp: 2015-09-26.
- [3] Jerzy Błaszczyński, Salvatore Greco, Roman Słowiński, and Marcin Szeląg. Monotonic variable consistency rough set approaches. 2009. *International Journal of Approximate Reasoning*, 50, pp. 979–999.
- [4] Jerzy Błaszczyński, Roman Słowiński, and Marcin Szeląg. Sequential covering rule induction algorithm for variable consistency rough set approaches. 2011. *Information Sciences*, 181, pp. 987-1002.
- [5] Leo Breiman. Bagging predictors.
- [6] Robert Brylla, Ricardo Gutierrez-Osuna, and Francis Quek. Attribute bagging: improving accuracy of classifier ensembles by using random feature subsets.
- [7] Yanping Chen, Eamonn Keogh, Bing Hu, Nurjahan Begum, Anthony Bagnall, Abdullah Mueen, and Gustavo Batista. The ucr time series classification archive, July 2015. www.cs.ucr.edu/~eamonn/time_series_data/, ostatni dostęp 24.09.2015.
- [8] Diane J. Cook and Narayanan C. Krishnan. *Activity Learning: Discovering, Recognizing, and Predicting Human Behavior from Sensor Data (Wiley Series on Parallel and Distributed Computing)*. Wiley, 2015.
- [9] Johannes Furnkranz. Separate-and-conquer rule learning. 1999. *Artificial Intelligence Review*, 13, pp. 3–54.
- [10] Salvatore Greco, Benedetto Matarazzo, Roman Słowiński, and Jerzy Stefanowski. An algorithm for induction of decision rules consistent with the dominance principle. 2000. In *Rough Sets and Current Trends in Computing* (W. Ziarko and Y. Y. Yao, eds.), vol. 2005 of *Lecture Notes in Computer Science*. Springer, 304–313.
- [11] Jerzy W. Grzymała-Busse. Lers - a system for learning from examples based on rough sets. in *intelligent decision support: Handbook of applications and advances of the rough sets theory* (r. słowiński, ed.). 1992. Kluwer Academic Publishers, pp. 3–18.

- [12] Roger Jang. *Data Clustering and Pattern Recognition*. <http://mirlab.org/jang/books/dcpr/>, ostatni dostęp 24.09.2015.
- [13] Jessica Lin, Eamonn Keogh, Stefano Lonardi, and Bill Chiu. A symbolic representation of time series, with implications for streaming algorithms. pages 2–11, 2003.
- [14] Robert C. Martin. Design principles and design patterns. = <http://citeseerx.ist.psu.edu/viewdoc/summary?doi=10.1.1.94.8854>.
- [15] Ryszard S. Michalski. On the quasi-minimal solution of the covering problem. 1969. In Proceedings of the 5th International Symposium on Information Processing (FCIP-69) vol. A3 (Switching Circuits). Bled, Yugoslavia, , 181, pp. 125–128.
- [16] Robert H. Shumway and David S. Stoffer. *Time Series Analysis and Its Applications: With R Examples (Springer Texts in Statistics)*. Springer, 2010.
- [17] Jerzy Stefanowski. Analiza szeregów czasowych - wykład. 2009. Ostatni dostęp: 2015-09-26.
- [18] Jerzy Stefanowski. Metody predykcji – analiza regresji - wykład. 2009. Ostatni dostęp: 2015-09-26.